

Modelo logístico

Leo Bastos

leonardo.bastos{@fiocruz.br; @impatech.edu.br}

Impa Tech

<https://github.com/lrbastos/md32>

Regressão logística múltipla

- O modelo logístico multivariado múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i),$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k \Rightarrow \frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b\beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$

Exemplo: Fumo na gestação versus baixo peso

- Em um estudo observacional sobre tabagismo na gestação realizado em um certo hospital, uma amostra de 189 puérperas foi aleatoriamente selecionada.
- Foi verificado se as mulheres fumaram ou não durante a gestação.
- o peso do recém nascido foi registrado, e categorizado como baixo peso sim ou não.
- Os dados observados foram

Fumou durante a gestação?	Baixo peso ao nascer?	
	Sim	Não
Sim	30	44
Não	29	86

- Quem é o desfecho, Y ?
- Quem é a variável explicativa, X ?
- Como é o modelo?

$$Y_i \mid X_i = x_i \sim \text{Bernoulli}(\theta_i)$$

onde $\text{logit}(\theta_i) = \alpha + \beta x_i$, $i = 1, 2, \dots, n$.

- No R, usamos a função *glm*

```
> saida <- glm(low ~ smoke,  
+               family=binomial(link = 'logit'),  
+               data=birth)
```
- Precisamos especificar a família, nesse caso é a Binomial (Lembrem-se que a $Bernoulli(\theta) = Binomial(1, \theta)$)
- A função de ligação default é a logit.

Saída R: glm()

- A saída da função *glm* é bastante similar a saída da função *lm*

```
Call: glm(formula = low ~ smoke, family = binomial(link = "logit"),
  data = birth)
```

Coefficients:

(Intercept)	smokesim
-1.0871	0.7041

Degrees of Freedom: 188 Total (i.e. Null); 187 Residual

Null Deviance: 234.7

Residual Deviance: 229.8 AIC: 233.8

- Calculando a OR

```
> exp(0.7041)
```

```
[1] 2.022026
```

- As chances de um bebê com baixo peso para uma gestante fumante são 2,02 vezes as chances de baixo peso para uma gestante não fumante.

Saidas no R

Call:

```
glm(formula = low ~ smoke, family = binomial(link = "logit"),  
     data = birth)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.0871	0.2147	-5.062	4.14e-07	***
smokesim	0.7041	0.3196	2.203	0.0276	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 234.67 on 188 degrees of freedom
Residual deviance: 229.80 on 187 degrees of freedom
AIC: 233.8

Number of Fisher Scoring iterations: 4

- Lembrando que

$$\hat{\beta} \rightarrow N(\beta, F^{-1}(\beta))$$

- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
 - Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Podemos calcular um IC de 95% de confiança para a OR (ou para β)
 - Um IC de 95% para a OR é dado pela exponencial do intervalo de 95% para β .
 - Note que dessa forma o intervalo para a OR não é mais simétrico em torno da estimativa pontual, mas continua sendo um IC de 95% válido.

- O IC para os coeficientes podemos ser calculados da seguinte forma

```
> cbind(saida$coef, confint(saida) )
```

		2.5 %	97.5 %
(Intercept)	-1.0870515	-1.5243118	-0.679205
smokesim	0.7040592	0.0786932	1.335154

- E o IC para o coeficiente é dado por

```
> exp(cbind(OR=saida$coef, confint(saida) ))[-1,]
```

	OR	2.5 %	97.5 %
	2.021944	1.081872	3.800582

- Se for de interesse (e o delineamento do estudo permitir) podemos estimar a probabilidade do desfecho ocorrer sob condições específicas das variáveis explicativas.
- Ou seja,

$$P(Y_i = 1|X = x) = \text{logit}^{-1}(\alpha + \beta x)$$

- Para o modelo logístico:

$$P(Y_i = 1|X = x) = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$$

- Logo, previsões para essas probabilidades são dados por

$$\hat{P}(Y_i = 1|X = x) = \frac{e^{\hat{\alpha} + \hat{\beta}x}}{1 + e^{\hat{\alpha} + \hat{\beta}x}}$$

No exemplo

- No exemplo, podemos estimar a probabilidade de bebê com baixo peso para mulheres que fumam e para mulheres que não fumam durante a gravidez.
- Basta usar a função *predict*

```
> birth.pred <- data.frame(smoke = c("sim", "nao"))  
> prev <- predict(saida, type = 'response',  
+                newdata = birth.pred)  
> prev  
  
          1          2  
0.4054054 0.2521739
```

Intervalo de confiança para a previsão

- Para evitar 'esquisitices' o intervalo de confiança para as previsões exigem um pouco mais de algebrismo.

```
> prev2 <- predict(saida, type = 'link',  
+                  newdata = birth.pred,  
+                  se.fit = T)
```

- Criando os intervalos

```
> birth.pred <- birth.pred %>%  
+   bind_cols(  
+     Prob = prev,  
+     Link = prev2$fit,  
+     Link.sd = prev2$se.fit  
+   )
```

- A tabela estimada:

	smoke	Prob	Link	Link.sd
1	sim	0.405	-0.383	0.237
2	nao	0.252	-1.087	0.215

- IC para $\eta = \alpha + \beta x$

	smoke	Link	Link.sd	LI	LS
1	sim	-0.383	0.237	-0.847	0.081
2	nao	-1.087	0.215	-1.508	-0.666

- IC para $\theta_x = \text{logit}^{-1}(\alpha + \beta x)$

	smoke	Prob	LI	LS
1	sim	0.405	0.300	0.520
2	nao	0.252	0.181	0.339

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.

Exemplo: Sífilis em usuários de drogas

```
> dados <- read.csv("../dados/DUsifilis.csv")  
> head(dados)
```

	sifilis	sexo	idade	faixaetaria
1	0	masculino	46	35 a 49 anos
2	0	masculino	29	25 a 34 anos
3	0	masculino	44	35 a 49 anos
4	0	masculino	20	18 a 24 anos
5	0	masculino	26	25 a 34 anos
6	0	masculino	39	35 a 49 anos

- $Sifilis \sim Sexo$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7975	0.1703	-4.68	0.0000
sexomascuino	-0.5443	0.2067	-2.63	0.0084

- $OR_{Sexo:Masculino} = 0.58$. (Qual a interpretação?)

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.

Mudando a categoria de base

- $Sifilis \sim Sexo + Idade$

```
> dados$sexo = relevel(factor(dados$sexo),  
+                             ref = "masculino")  
> m0Sex <- glm(sifilis ~ sexo,  
+              dados, family=binomial())  
> xtable(m0Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3418	0.1171	-11.46	0.0000
sexofeminino	0.5443	0.2067	2.63	0.0084

- $OR_{Sexo:Fem} = 1.72$

- $Sifilis \sim Sexo + faixaetaria$

```
> m1Sex <- glm(sifilis ~ sexo + faixaetaria,  
+              dados, family=binomial())  
> xtable(m1Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.0659	0.2463	-8.39	0.0000
sexofeminino	0.7422	0.2183	3.40	0.0007
faixaetaria25 a 34 anos	0.6171	0.2781	2.22	0.0265
faixaetaria35 a 49 anos	1.0353	0.2858	3.62	0.0003
faixaetaria50 anos ou mais	1.1607	0.3646	3.18	0.0015

- $OR_{Sexo:Fem} = 2.1$

- $Sifilis \sim Sexo + Idade$

```
> m2Sex <- glm(sifilis ~ sexo + idade,  
+             dados, family=binomial())  
> xtable(m2Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.5044	0.3490	-7.17	0.0000
sexofeminino	0.7342	0.2170	3.38	0.0007
idade	0.0329	0.0090	3.66	0.0003

- $OR_{Sexo:Fem} = 2.08$

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			604	659.34	
sexo	1	6.76	603	652.58	0.0093
faixaetaria	3	16.95	600	635.63	0.0007

- AIC

$$AIC = -2l(\hat{\beta}) + 2p$$

onde $-2l(\hat{\beta}) = Deviance$ é a deviance ou função desvio.

- R^2 ajustado

$$R_{adj}^2 = 1 - \left(1 - \frac{(n-1) Deviance}{(n-p) Deviance_0} \right)$$

onde $Deviance_0$ é a deviance do modelo nulo (só com intercepto).

AIC e R^2 ajustado

```
> AIC(m0Sex, m1Sex, m2Sex)
```

	df	AIC
m0Sex	2	656.5810
m1Sex	5	645.6326
m2Sex	3	645.1537

```
> glmtoolbox::adjR2(m0Sex, m1Sex, m2Sex)
```

	Deviance	R-squared	df	adj.R-squared
m0Sex	652.5810	0.01025	2	0.00860
m1Sex	635.6326	0.03595	5	0.02952
m2Sex	639.1537	0.03061	3	0.02739

- Sexo e faixa etária não são colineares ($\text{GVIF} < 10$)

```
> car::vif( glm(sifilis ~ sexo + faixaetaria,  
+              dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo          1.08117  1      1.039793  
faixaetaria 1.08117  3      1.013092
```

Multicolinearidade: Idade e faixa etária juntos

```
> summary( glm(sifilis ~ sexo + idade + faixaetaria,  
+             dados, family=binomial()) )
```

```
Call:  
glm(formula = sifilis ~ sexo + idade + faixaetaria, family = binomial(),  
     data = dados)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-2.099655	0.674332	-3.114	0.001848	**
sexofeminino	0.742434	0.218369	3.400	0.000674	***
idade	0.001634	0.030354	0.054	0.957058	
faixaetaria25 a 34 anos	0.602956	0.382346	1.577	0.114798	
faixaetaria35 a 49 anos	1.002031	0.681217	1.471	0.141307	
faixaetaria50 anos ou mais	1.106114	1.077052	1.027	0.304429	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 659.34 on 604 degrees of freedom
Residual deviance: 635.63 on 599 degrees of freedom
AIC: 647.63

Number of Fisher Scoring iterations: 4

- Calculando o GVIF

```
> car::vif( glm(sifilis ~ sexo + idade + faixaetaria,  
+              dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo           1.081758 1           1.040076  
idade          11.487130 1           3.389267  
faixaetaria 11.532768 3           1.503104
```

	OR	2.5 %	97.5 %
Bruto	1.72	1.15	2.58
Ajustado por faixa etária	2.10	1.37	3.22
Ajustado por idade	2.08	1.36	3.19

Tabela: Efeito do sexo (Base: Masculino) no log da chance de infecção por sífilis

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decis).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.

- Estatística de bondade de ajuste de Hosmer-Lemeshow, $\hat{C}$

$$\hat{C} = \sum_{k=1}^g \frac{(o_k - n'_k \bar{\pi}_k)^2}{n'_k \bar{\pi}_k (1 - \bar{\pi}_k)}$$

onde g é o número de grupos, n'_k número de observações no grupo k , o_k número de casos observados no grupo k , e $\bar{\pi}_k$ é média das probabilidade estimada no grupo k .

- $\hat{C} \rightarrow \chi^2_{g-2}$

Exemplo: Teste Hosmer-Lemeshow

Para o exemplo da sífilis, sexo e faixa etária geram 8 grupos, então $g = 8$

	Grupo	O_k	n'_k	$\hat{\theta}_k$	E_k
1	masculino : 18 a 24 anos	13	105	0.11	11.81
2	masculino : 25 a 34 anos	24	143	0.19	27.20
3	masculino : 35 a 49 anos	37	138	0.26	36.29
4	masculino : 50 anos ou mais	18	58	0.29	16.70
5	feminino : 18 a 24 anos	11	58	0.21	12.19
6	feminino : 25 a 34 anos	25	66	0.33	21.80
7	feminino : 35 a 49 anos	13	32	0.43	13.71
8	feminino : 50 anos ou mais	1	5	0.46	2.30

$$\hat{C} = 3.03 \rightarrow \text{p-valor} = 0.806$$

Teste Hosmer-Lemeshow no R

```
> glmtoolbox::hltest(m1Sex)
```

The Hosmer-Lemeshow goodness-of-fit test

Group	Size	Observed	Expected
1	105	13	11.808265
2	143	24	27.197188
3	58	11	12.191735
4	138	37	36.291221
5	58	18	16.703326
6	66	25	21.802812
7	32	13	13.708779
8	5	1	2.296674

Statistic = 3.02556

degrees of freedom = 6

p-value = 0.80563

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes

Outliers: Medidas de influência

```
> summary(influence.measures(m1Sex))
```

Potentially influential observations of

```
glm(formula = sifilis ~ sexo + faixaetaria, family = binomial(), data = data)
```

	dfb.1_	dfb.sxfrm	dfb.fa3a	dfb.fa4a	dfb.faom	dffit	cov.r	cook.d	hat
103	-0.05	0.12	0.01	0.02	0.16	0.21	1.03_*	0.01	0.03_*
104	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
143	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
384	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
560	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Podemos explicar a probabilidade de sobreviver segundo sexo e idade
- Podemos comparar as probabilidades (ou avaliar as ORs) associadas a sobrevivência entre os sexos, e entre os dois grupos de idade.
- Então, basta calcularmos as ORs

$$OR_{Sex:Female} = \frac{Odds(Female)}{Odds(Male)}$$

e

$$OR_{Age:Child} = \frac{Odds(Child)}{Odds(Adult)}$$

Lendo os dados no R

- Chamando o banco

```
> data("Titanic")  
> Titanic2 <- Titanic |> as_tibble() |>  
+   pivot_wider(names_from = Survived, values_from = n)  
> head(Titanic2, n = 5)
```


```
# A tibble: 5 × 5
```

	Class	Sex	Age	No	Yes
	<chr>	<chr>	<chr>	<dbl>	<dbl>
1	1st	Male	Child	0	5
2	2nd	Male	Child	0	11
3	3rd	Male	Child	35	13
4	Crew	Male	Child	0	0
5	1st	Female	Child	0	1

- Transformando em fatores e definindo categorias de base

```
> Titanic2 <- Titanic2 |>  
+   mutate(  
+     Sex = factor(Sex) |> relevel(ref = "Male"),  
+     Age = factor(Age) |> relevel(ref = "Adult"),  
+     Class = factor(Class) |> relevel(ref = "Crew")  
+   )
```

Visualizando: Sobrevivência por sexo




- Tabela para Sexo

	Sex	Surv:Yes	Surv:No
1	Male	367	1364
2	Female	344	126

- $OR_{Sex:Female} = \frac{1364 \cdot 344}{367 \cdot 126} = 10.15$
- As chances de uma mulher sobreviver ao naufrágio são 10.15 vezes as chances de um homem sobreviver.

Visualizando: Sobrevivência por idade



- Tabela para Sexo

	Age	Surv:Yes	Surv:No
1	Adult	654	1438
2	Child	57	52

- $OR_{Age:Child} = \frac{57 \cdot 1438}{52 \cdot 654} = 2.41$
- As chances de uma criança sobreviver ao naufrágio são 2.41 vezes as chances de um adulto sobreviver.

- O modelo logístico tem a forma

$$Y_i \sim \text{Ber}(\theta_i)$$

onde $Y_i = 1$ se o indivíduo sobreviveu, $g(\theta_i) = \alpha + \beta X_i$

- Se o dado estiver agregado, cada linha representa um conjunto de categorias, podemos escrever o modelo da seguinte forma
- O modelo logístico tem a forma

$$Z_k \sim \text{Bin}(n_k, \theta_k)$$

onde Z_k é o número de sobreviventes na linha k , n_k o número de passageiros na linha k , e $g(\theta_k) = \alpha + \beta X_k$

Olhando o dado agregado

- O dado em sua forma agregada

```
> head(Titanic2)
```

```
# A tibble: 6 × 5
```

	Class	Sex	Age	No	Yes
	<fct>	<fct>	<fct>	<dbl>	<dbl>
1	1st	Male	Child	0	5
2	2nd	Male	Child	0	11
3	3rd	Male	Child	35	13
4	Crew	Male	Child	0	0
5	1st	Female	Child	0	1
6	2nd	Female	Child	0	13

Modelos para dados agregados

```
> m0Sex <- glm(cbind(Yes, No) ~ Sex,  
+             data = Titanic2,  
+             family=binomial())  
> m0Age <- glm(cbind(Yes, No) ~ Age,  
+             data = Titanic2,  
+             family=binomial())
```

- $(Surv : Y, Surv : N) \sim Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3128	0.0588	-22.33	0.0000
SexFemale	2.3172	0.1196	19.38	0.0000

- $OR_{SexFemale} = 10.15$

- $(Surv : Y, Surv : N) \sim Age$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7879	0.0472	-16.71	0.0000
AgeChild	0.8797	0.1975	4.45	0.0000


- $OR_{Age:Child} = 2.41$

- Podemos encontrar as ORs ajustadas, i.e. a OR do sexo ajustada por idade, e a OR da idade ajustada pelo sexo.
- $(Surv : Y, Surv : N) \sim Age + Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3365	0.0599	-22.32	0.0000
SexFemale	2.2940	0.1199	19.13	0.0000
AgeChild	0.5564	0.2276	2.44	0.0145

- $OR_{SexFemale} = 9.91$ e $OR_{AgeChild} = 1.74$

Visualizando: Sobrevivência por idade e sexo



- $(Surv : Y, Surv : N) \sim Age$ (para os homens)

	Estimate	Std. Error	z value	$Pr(> z)$
(Intercept)	-1.3691	0.0609	-22.47	0.0000
AgeChild	1.1811	0.2584	4.57	0.0000

- $(Surv : Y, Surv : N) \sim Age$ (para as mulheres)

	Estimate	Std. Error	z value	$Pr(> z)$
(Intercept)	1.0644	0.1111	9.58	0.0000
AgeChild	-0.5654	0.3269	-1.73	0.0837

Criando uma categoria única Sexo e idade

- Agora vamos criar uma categoria para sexo e idade, vamos chamá-la de SexAge.
- $(Surv : Y, Surv : N) \sim AgeSex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3691	0.0609	-22.47	0.0000
AgeSexAdult:Female	2.4335	0.1267	19.21	0.0000
AgeSexChild:Female	1.8681	0.3134	5.96	0.0000
AgeSexChild:Male	1.1811	0.2584	4.57	0.0000

- Lembrando que podemos recuperar as probabilidades aplicando a função logit inversa,

$$\hat{\theta} = \text{logit}^{-1}\left(\alpha + \sum_i \text{AgeSex}_i \hat{\beta}_i\right)$$

- Resultando na tabela:

	Levels	OR	SurvProb	LI	LS
1	Adult:Male	1.000	0.203	0.184	0.223
2	Adult:Female	11.399	0.744	0.700	0.783
3	Child:Female	6.476	0.622	0.474	0.751
4	Child:Male	3.258	0.453	0.336	0.575


- Comparando modelos via AIC

	Modelos	AIC
1	1 + Age	703.02
2	1 + Sex	288.11
3	1 + Age + Sex	284.22
4	1 + AgeSex	269.90

Conclusão?

- E aí, Mulheres e crianças primeiro?
- Mulheres adultas primeiro, depois crianças!

Visualizando: Sobrevivência por classe



- $(Surv : Y, Surv : N) \sim AgeSex + Class$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.2389	0.0807	-15.35	0.0000
AgeSexAdult:Female	2.6172	0.1510	17.33	0.0000
AgeSexChild:Female	2.5072	0.3332	7.52	0.0000
AgeSexChild:Male	1.7921	0.2829	6.33	0.0000
Class1st	0.8033	0.1598	5.03	0.0000
Class2nd	-0.2305	0.1771	-1.30	0.1932
Class3rd	-1.0072	0.1530	-6.58	0.0000

- ORs por classe (Baseline: Crew)

	OR	LI	LS
Class1st	2.23	1.63	3.05
Class2nd	0.79	0.56	1.12
Class3rd	0.37	0.27	0.49

- ORs por Idade e sexo (Baseline: Adult:Male)

	OR.crude	OR.adj
AgeSexAdult:Female	11.40	13.70
AgeSexChild:Female	6.48	12.27
AgeSexChild:Male	3.26	6.00

- $(Surv : Y, Surv : N) \sim AgeSex$ (AIC = 269.9)
- $(Surv : Y, Surv : N) \sim AgeSex + Class$ (AIC = 155.2)

Probabilidades de sobrevivência

