Modelo logístico na epidemiologia

Leo Bastos
leonardo.bastos{@fiocruz.br; @impatech.edu.br}

Impa Tech

https://github.com/lsbastos/md32

impatech

Outline

1. Principais desenhos epidemiológicos

2. Medidas de associação ajustadas
   - OR ajustada
   - RR ajustado, algumas abordagens

3. GLM para amostras complexas

impa tech

Ensaio Clínico Randomizado (ECR)

- **Conceito:** Estudo experimental e prospectivo no qual o pesquisador aloca aleatoriamente os participantes em grupos de intervenção (ex.: tratamento) ou controle (ex.: placebo).
- **Estrutura Temporal:** $T_0 \rightarrow T_1$ (Acompanhamento prospectivo após a intervenção).
- **Lógica Quantitativa:** Avalia a causalidade direta ao minimizar viés de confusão por meio do processo de randomização.
- **Medida de Associação Típica: Risco Relativo (RR)**

$$RR = \frac{P(Y = 1 \mid X = 1)}{P(Y = 1 \mid X = 0)}$$



Estudo de Coorte

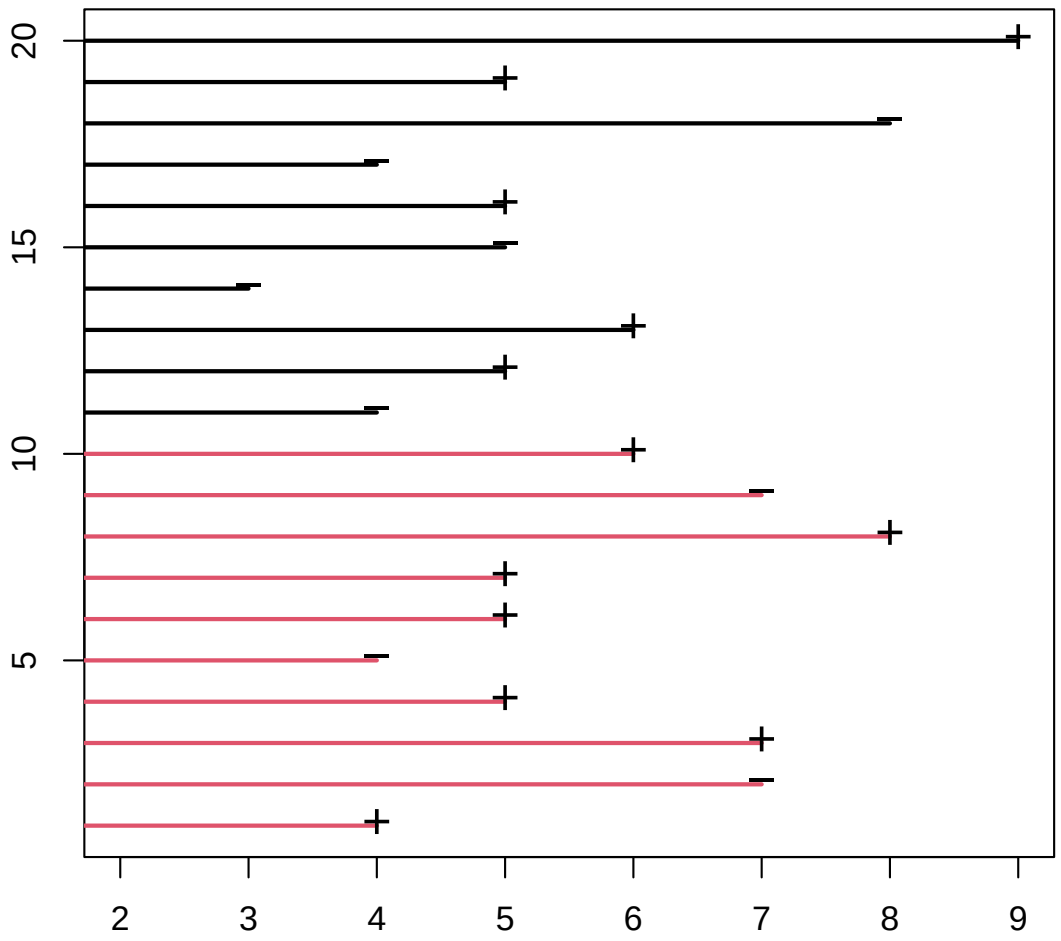
- **Conceito:** Estudo observacional que parte da classificação quanto à **exposição** a um fator de risco/proteção e acompanha os indivíduos ao longo do tempo para observar a incidência do **desfecho**.
- **Estrutura Temporal:** Exposição em $T_0 \rightarrow$ Observação do desfecho em T_1.
- **Lógica Quantitativa:** Permite o cálculo direto da taxa de incidência nos grupos exposto e não exposto.
- **Medida de Associação Típica: Risco Relativo (RR)** e Razão de Taxas de Incidência.

$$RR = \frac{P(Y = 1 \mid X = 1)}{P(Y = 1 \mid X = 0)} \qquad HR = \frac{h(t; X = 1)}{h(t; X = 0)}$$



impa tech

Exemplo coorte



Time in the study
(black group − control; red group − exposed)

impa tech

Estudo Caso-Controle

- **Conceito:** Estudo observacional retrospectivo que parte da seleção do **desfecho** (Casos = doentes; Controles = hígidos) e investiga o histórico de **exposição** passada.
- **Estrutura Temporal:** Desfecho em $T_0 \leftarrow$ Investigação retrospectiva da exposição em T_{-1}.
- **Lógica Quantitativa:** Como a amostragem se baseia na doença, não é possível calcular a incidência diretamente na população. Avalia-se a chance relativa de exposição anterior.
- **Medida de Associação Típica: Odds Ratio (OR)** (Razão de Chances).

$$OR = \frac{odd(X=1)}{odd(X=0)} = \frac{P(Y=1 \mid X=1)/P(Y=0 \mid X=1)}{P(Y=1 \mid X=0)/P(Y=0 \mid X=0)}$$

impatech

Estudo Transversal (*Cross-Sectional*)

- **Conceito:** Estudo observacional no qual a **exposição e o desfecho são mensurados simultaneamente** em um único ponto no tempo (amostra pontual).
- **Estrutura Temporal:** Exposição e Desfecho avaliados simultaneamente no tempo T_0.
- **Lógica Quantitativa:** Estima a **prevalência** da condição. A limitação principal é a impossibilidade de determinar causalidade temporal (ambiguidade temporal).
- **Medida de Associação Típica: Razão de Prevalência (RP)** ou Odds Ratio de Prevalência.

$$PR = \frac{P(Y = 1 \mid X = 1)}{P(Y = 1 \mid X = 0)} \qquad POR = \frac{odd(X = 1)}{odd(X = 0)}$$



impatech

Medidas de associação ajustadas

Quando precisamos controlar por outras variáveis explicativas

- Razão de chances (aOR) – Modelo logístico

$$aOR_X = \frac{P(Y = 1 \mid X = 1, Z = z)/P(Y = 0 \mid X = 1, Z = z)}{P(Y = 1 \mid X = 0, Z = z)/P(Y = 0 \mid X = 0, Z = z)}$$

- Razão de riscos (aRR) ou de prevalencias (aRP) – Modelo log-binomial, regressão de Poisson (com variância robusta), regressão logística*,...

$$aRR_X = \frac{P(Y = 1 \mid X = 1, Z = z)}{P(Y = 1 \mid X = 0, Z = z)}$$

- Razão de taxas (aHR) – Análise de sobrevivência (e.g. Modelo de Cox)



impatech

Modelo para dados binários

- Seja $Y_1, Y_2, \ldots, Y_n$ variáveis aleatórias independentes
- O desfecho é binário, i.e. $Y_i = \{0, 1\}$
- Assume-se que

$$Y_i \sim Bern(\theta_i)$$

onde $\theta_i = P(Y_i = 1) \in (0, 1)$.

- Sabemos que $\mathbb{E}[Y_i] = \mu_i = \theta_i$.
- O componente sistemático está relacionado com o componente aleatório através da função de ligação, i.e.

$$g(\mu_i) = \mathrm{x}_i^T \boldsymbol{\beta} = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi}$$

onde $g(\cdot) : (0, 1) \to \mathbb{R}$.



Possíveis funções de ligação

- **Modelo logístico**
  Ligação logit: $g(\cdot) = logit(\cdot)$

$$logit(\theta_i) = \mathrm{x}_i^T \boldsymbol{\beta} \quad \rightarrow \quad \theta_i = P(Y_i = 1 | \mathrm{X} = \mathrm{x_i}) = \frac{e^{\mathrm{x}_i^T \boldsymbol{\beta}}}{1 + e^{\mathrm{x}_i^T \boldsymbol{\beta}}}$$

- **Modelo log-binomial**
  Ligação Log: $g(\cdot) = \log(\cdot)$

$$\log(\theta_i) = \mathrm{x}_i^T \boldsymbol{\beta}^* \quad \rightarrow \quad \theta_i = P(Y_i = 1 | \mathrm{X} = \mathrm{x_i}) = e^{\mathrm{x}_i^T \boldsymbol{\beta}^*}$$



Odds ratio via regressão logística

- Sem perda de generalidade (SPG), suponha que queremos encontrar a OR para a variável X_1, OR_1, controlando pelas demais $(X_2, \ldots, X_p)$.
- A OR_1 ajustada é dada por:

$$aOR_1 = \frac{\frac{P(Y=1|X_1=1,X_2=x_2,\ldots,X_k=x_k)}{P(Y=0|X_1=1,X_2=x_2,\ldots,X_k=x_k)}}{\frac{P(Y=1|X_1=0,X_2=x_2,\ldots,X_k=x_k)}{P(Y=0|X_1=0,X_2=x_2,\ldots,X_k=x_k)}}$$

- Na regressão logística, essa razão se reduz a

$$OR_1 = e^{\beta_1}$$

para quaisquer valores das outras variáveis, desde fixos em um mesmo valor.



impa tech

Odds ratio via regressão logística

- Ao estimarmos β_1 em um modelo com as outras $p-1$ variáveis, estamos então controlando ou ajustando pelas variáveis $X_2, \ldots, X_p$.
- A OR estimada é chamada de OR ajustada.
- A OR pode ser calculada em todos os desenhos: ensaio clínico, coorte, caso-controle e seccional.
- Um propriedade: quanto menor a probabiliade do desfecho, melhor a aproximação do uso da OR como Risco relativo (ou razão de prevalência).



Razão de riscos (ou prevalências)

- A Razão de risco ou risco relativo, RR, pode ser calculada diretamente em estudos de coorte, e em estudos seccionais (razão de prevalências).
- SPG, suponha que queremos encontrar a RR para a variável X_1, RR_1, controlando pelas demais $(X_2, z \ldots, X_p)$.
- O RR_1 ajustada é dada por:

$$aRR_1 = \frac{P(Y = 1|X_1 = 1, X_2 = x_2, \ldots, X_k = x_k)}{P(Y = 1|X_1 = 0, X_2 = x_2, \ldots, X_k = x_k)}$$

- Em um modelo log-binomial, essa razão se reduz a

$$RR_1 = \frac{e^{\beta_0+\beta_1+\beta_2 x_2+\ldots+\beta_k x_k}}{e^{\beta_0+\beta_2 x_2+\ldots+\beta_k x_k}} = e^{\beta_1}$$

- Como a função de ligação não é uma função $g(\cdot) : (0, 1) \to$ [redacted]ntão pode-se observar instabilidade numérica na estimação.

impa tech

Alternativas para o cálculo do risco relativo

- O método mais popular é a regressão de Poisson com variância robusta, Barros e Hirakata (2003, BMC) e Zou (2004, AJE).
- A ideia, ajustar um modelo de Poisson aos dados binários, e usar um método robusto de correção de variância para estimar a incerteza dos efeitos.
- Usa uma equivalência matematica entre a função de verossimilhança da distribuição de Poisson com um modelo de risco proporcionais de Cox com modificação de Breslow.
- A variância dos estimadortes é corrigida usando um método de estimação da matriz de variâncias heterocedástico-consistente, o R tem 9(!) estimadores. O default chamado HC3, é o melhor segundo um estudo de simulação (Long & Ervin, 2000, The American Statistician) para modelos lineares.



impa tech

Regressão para dados binários

- Seja $Y_1, Y_2, \ldots, Y_n$ variáveis aleatórias binárias independentes
- Assume-se que

$$Y_i \sim Poisson(\lambda_i)$$

onde λ_i é uma taxa.

- Usando a função de ligação log, temos que

$$\log(\lambda_i) = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi}$$

- Agora não há problema de instabilidade numérica, e a Razão de taxas para a variável X_1 pode ser estimada

$$aRR_1 = \frac{\lambda_{X_1=1}}{\lambda_{X_1=0}} = e^{\beta_1}$$



impa tech

Regressão para dados binários

- No R, usa-se a função *glm* de forma usual, em seguida corrigi-se a variância usando os pacotes *lmtest* e *sandwich*
- As estimativas corrigidas são obtidas com a função:

  coeftest(modeloPoisson, vcov.=vcovHC(modeloPoisson, type="HC3"))

  onde *modeloPoisson* é a saída do ajuste modelo de Poisson aos dados binários
- Uma estimativa para o risco relativo (asism como a razão de prevalência) pode ser calculada diretamente da regressão logística.



Estimando RR diretamente da regressão logística

- A ideia foi proposta por Wilcosky and Chambless (1985), é funciona da seguinte maneira:
  - O RR é essencialmente a razão das seguintes probabilidades:

$$aRR_1 = \frac{P(Y = 1|X_1 = 1, \mathrm{X}_{-1} = \mathrm{x}^*_{-1})}{P(Y = 1|X_1 = 0, \mathrm{X}_{-1} = \mathrm{x}^*_{-1})}$$

  - Na regressão logística vimos que

$$P(Y = 1|X_1 = x, \mathrm{X}_{-1} = \mathrm{x}_{-1}) = \frac{e^{\beta_0+\beta_1 x+\beta_2 x_2^*+\ldots\beta_p x_p^*}}{1 + e^{\beta_0+\beta_1 x+\beta_2 x_2^*+\ldots\beta_p x_p^*}}$$

  - Dessa forma a razão que temos interesse é:

$$aRR_1 = e_1^{\beta} \frac{1 + e^{\beta_0+\beta_2 x_2^*+\ldots\beta_p x_p^*}}{1 + e^{\beta_0+\beta_1+\beta_2 x_2^*+\ldots\beta_p x_p^*}}$$

- Note que risco relativo ajustado depende de uma variadade dos efeitos $(\beta_0, \beta_1, \ldots, \beta_p)$, e dos valores fixados para as variáveis de confundimento $(x_2^*, \ldots, x_p^*)$.



Estimando RR diretamente da regressão logística

- Os efeitos de regressão β são estimados diretamente do modelo
- Wilcosky and Chambless (1985) proporam algumas formas para lidar com as outras covariáveis:
  1. RR marginal: A ideia é calcular o risco relativo médio da amostra

$$RR_1^{(m)} = \frac{\sum_{i=1}^{n} P(Y = 1|X_1 = 1, X_2 = x_{2i}, \ldots, X_p = x_{pi})}{\sum_{i=1}^{n} P(Y = 1|X_1 = 0, X_2 = x_{2i}, \ldots, X_p = x_{pi})}$$

  2. RR condicional: A ideia é calcular o risco relativo para um indivíduo médio da amostra

$$RR_1^{(c)} = \frac{P(Y = 1|X_1 = 1, X_2 = \bar{x}_2, \ldots, X_p = \bar{x}_p)}{P(Y = 1|X_1 = 0, X_2 = \bar{x}_2, \ldots, X_p = \bar{x}_p)}$$

  3. Lembrando que

$$P(Y = 1|X_1 = x, X_2 = x_2^*, \ldots, X_p = x_p^*) = \frac{e^{\beta_0 + \beta_1 x + \beta_2 x_2^* + \ldots \beta_p x_p^*}}{1 + e^{\beta_0 + \beta_1 x + \beta_2 x_2^* + \ldots \beta_p x_p^*}}$$

Estimando RR diretamente da regressão logística

- Teoria assintótica para $RR^{(m)}$ e $RR^{(c)}$ foi desenvolvida por Flanders and Rhodes (1987)
- Um pacote para estimar $RR^{(m)}$ e $RR^{(c)}$, e seus respectivos erro padrão e IC, está em desenvolvimento.
- Exemplo tirado de Barros & Hirakata (2003)
  - Com o objetivo de avaliar a ocorrencia de baixo peso em crianças de 4-5 anos em Pelotas/RS (desfecho) por hospitalização prévia (exposição), controlado por peso ao nascer (normal ou baixo peso).

		Peso atual	
Z	X	Baixo peso	Normal
Normal	Sim	8	163
	Não	14	704
Baixo peso	Sim	16	103
	Não	14	250

Source: Data from Table 1 of Barros and Hirakata (2003)



impa tech

Resultados

Tabela: Prevalence ratios (PR) and respective 95% confidence interval estimates in the analysis of the data using underweight as the outcome (Y), previous hospitalization (X) as the risk factor and birth weight as control factor (Z).

	PR	95% CI
Crude *PR*	2.902	(1.710, 4.927)
Crude *POR*	3.071	(1.673, 5.597)
Robust Poisson	2.479	(1.454, 4.226)
Log-binomial	2.481	(1.447, 4.226)
Logistic regression		
aPOR	2.641	(1.481, 4.671)
$aPR_X^{(c)}$	2.532	(1.471, 4.357)
$aPR_X^{(m)}$	2.460	(1.451, 4.171)

Note: *POR* =Prevalence odds ratio and *PR* = Prevalence ratio.



impa tech

GLM para amostras complexas

- A primeira suposição de um GLM, seja $Y_1, Y_2, \ldots, Y_n$ desfechos independentes.
- Isso é equivalente a supor que a amostra observada é uma amostra aleatória simples (com reposição) ou de uma população infinita.
- Em muitos estudos a seleção da amostra é proveniente de um plano amostral complexo, e portanto a suposição essa suposição de AAS pode ser muito forte.
- Em um plano amostral probabilístico, devemos ser capazes de calcular a probabilidade de cada elemento da população pertencer a amostra.
- Essa probabilidade é definida pelo desenho da amostra e é posteriormente usada na modelagem.

impa tech

GLM para amostras complexas

- A probabilidade de inclusão de cada indivíduo, π_i, vai definir o peso amostral de cada indivíduo.
- Usualmente o peso, ω_i, é o inverso da probabilidade de inclusão, mas existem correções para o peso (ex. calibração)
- Tipos de amostragem:
  1. Aleatória simples;
  2. Estratificada;
  3. Por conglomerados em 1,2,3,... estágios;
  4. Combinações das amostras acima.

impa tech

GLM para amostras complexas

- A não inclusão do desenho amostral pode causar viés nas estimativas de um modelo.
- Isso acontece, pois algumas observações podem ter pesos diferentes podendo distorcer a associação entre variáveis.
- Existem algumas maneiras distintas de incluir o desenho amostral na análise, aqui vamos olhar para o método da pseudo-verossimilhança.
- No método da pseudo-verossimilhança os pesos são incluídos multiplicando a função escore.

$$s(\beta) = \sum_{i=1}^{n} \omega_i s_i(\beta)$$

- Dessa forma, estimativas corrigidas para os efeitos, e principalmente, para as variâncias podem ser calculadas ao incluir os pesos que definem o plano amostral utilizado.

impa tech

GLM para amostras complexas

- O pacote *survey* do R faz isso.
- Referências:
  - Analysis of Survey Data. Edited by R. L. Chambers and C. J. Skinner, John Wiley & Sons, Ltd. 2003
  - Complex survey: A guide to analysis using R, Thomas Lumley, John Wiley & Sons, Ltd. 2010



impa tech

Exemplo

- API (Academic Performance Index) foi calculado para todas as escolas da California baseado no resultado padronizado de testes dos estudantes (min=200, max=1000).
- 200 escolas foram selecionadas segundo uma amostra estratificada por tipo de escola (Elementary/Middle/High school).
- População: $N = 4421$. População dos estratos: $N_E = 4421$, $N_M = 1018$, $N_H = 755$.
- Variáveis de interesse:
  1. Desfecho – $API \geq 800$;
  2. ell – % de 'English-Language learners';
  3. meals – % de estudantes elegíveis a refeições subsidiadas.

impa tech

Comandos no R

```
> require(survey)
> data(api)
> des<-svydesign(id=~1,strata=~stype,
+                weights=~pw, data=apistrat, fpc=~fpc)
> m1 = glm(I(api00 >= 800) ~ ell + meals,
+          family=binomial(), data=apistrat)
> m2 = svyglm(I(api00 >= 800) ~ ell + meals,
+             family=binomial(), design=des)
```

impatech

Saída GLM

- Modelo logístico usual

	Estimate	Std. Error	z value	Pr(>|z|)
(Intercept)	0.5879	0.4211	1.40	0.1626
ell	0.0656	0.0377	1.74	0.0817
meals	-0.1333	0.0308	-4.32	0.0000

- Modelo logístico usando o desenho amostral

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	1.3035	0.3710	3.51	0.0005
ell	0.0708	0.0377	1.88	0.0622
meals	-0.1421	0.0291	-4.88	0.0000



impa tech

Saída GLM

- Odds ratios: Aumentando em 1 unidade percentual

	Coef	2.5 %	97.5 %
ell	1.07	1.00	1.16
meals	0.87	0.82	0.92

- OR: Aumentando em 10 unidades percentuais

	Coef	2.5 %	97.5 %
ell	2.03	0.96	4.27
meals	0.24	0.14	0.43

impa tech