Modelos Lineares Generalizados
Dados multinomias e ordinais

Leo Bastos

Fundação Oswaldo Cruz

UFF



Resposta categorica

- Vimos como tratar desfechos categóricos dicotômicos
  Distribuição binomial $\rightarrow$ Regressão binária.
- A partir de agora, vamos considerar desfechos categóricos independentes com mais que duas categorias. Distribuição multinomial:
  - Regressão multinomial (modelo de escolha discreta, modelo de regressão logística politômico, etc.)
  - Regressão ordinal (Caso as categorais possam ser completamente ordenadas)
- Para simplificar usaremos 3 ou 4 categorias, mas todos os resultados podem ser generalizados para J categorias.



Exemplo: Multinomial

- Considere um estudo de escolha de um plano de saúde dentre 3 planos oferecidos aos funcionários de uma empresa de grande porte.
- A variável desfecho é um dos 3 planos de saúde: A, B ou C.
- Possíveis covariáveis que podem influenciar essa escolha: Sexo, idade, renda, tamanho da família, etc.
- O objetivo é modelar as razões de chances dos planos como função das covariáveis.
- Tal modelo é o que chamamos de modelo multinomial (McFadden, 1974).



Exemplo 2: Multinomial

- Dieta de jacarés nos canais do recreio e Barra. 57 jacarés foram capturados, medidos e foi observado sua ultima alimentação.
- Os jacarés foram classificados pelo tamanho {pequeno,grande} e pelo tipo de alimentação principal: {peixes, invertebrados, outros}
- Os dados observados foram:

	Peixe	Inv.	Outro
Gde	16	8	8
Pq	5	15	5

- Como calculamos as razões de chances, OR, para esse caso? Lembrando que o desfecho é o tipo de alimentação.



Escrevendo as ORs

- $Y = \{0, 1, 2\}$ representa respectivamente o tipo de alimentação Invertebrado, peixe, outros.
- Devemos definir um possível desfecho como base. (Invertebrados)
- A razão de chances de um jacaré ter alimentação base peixes versus invertebrados para a variável tamanho grande ($X = 1$) versus pequeno ($X = 0$) é:

$$OR_1 = \frac{\frac{P(Y=1|X=1)}{P(Y=0|X=1)}}{\frac{P(Y=1|X=0)}{P(Y=0|X=0)}} = \frac{P(Y = 1|X = 1)P(Y = 0|X = 0)}{P(Y = 0|X = 1)P(Y = 1|X = 0)}$$

- Analogamente, a razão de chances de um jacaré ter alimentação base outros versus invertebrados para a variável tamanho grande ($X = 1$) versus pequeno ($X = 0$) é:

$$OR_2 = \frac{P(Y = 2|X = 1)P(Y = 0|X = 0)}{P(Y = 0|X = 1)P(Y = 2|X = 0)}$$



Calculando ORs

- Calculando OR_1

$$OR_1 = \frac{16 * 15}{8 * 5} = 6$$

as chances de um jacaré ter peixes como alimentação base ao invés de invertebrados para jacarés grandes é 6 vezes as chances para jacarés pequenos.

- Calculando OR_2

$$OR_2 = \frac{8 * 15}{5 * 8} = 3$$

as chances de um jacaré ter 'outros' como alimentação base ao invés de invertebrados para jacarés grandes é 3 vezes as chance para jacarés pequenos.



Como escrever um modelo para isso?

1. Qual a distribuição do desfecho?
2. As observações são independentes?
3. Como podemos incluir outras variáveis explicativas? Espécie do jacaré, sexo, etc.



Distribuição multinomial

- Construindo o **vetor** aleatório:
  - Suponha que temos um desfecho com três categorias. $\{A, B, C\}$
  - Seja $\mathbf{Z} = (Z_A, Z_B, Z_C)$, tal que $Z_A = 1$ se $Y = A$, e $Z_A = 0$ caso contrário.
- Se fizermos n observações independentes, dizemos que os totais observados para cada categoria, $\mathbf{Y} = (Y_A, Y_B, Y_C)$, seguem uma distribuição multinomial se

$$P(\mathbf{Y} = \mathbf{y}|\mathbf{y}) = \frac{n!}{y_A! y_B! y_C!} \theta_A^{y_A} \theta_B^{y_B} \theta_C^{y_C}$$

  onde θ_i é a probabilidade do desfecho ser da categoria i, $\sum_i \theta_i = 1$, e $\sum y_i = n$.
- Como $\sum_i \theta_i = 1$, então por exemplo $\theta_C = 1 - \theta_A - \theta_B$. Logo temos apenas 2 parâmetros desconhecidos.



Construindo o modelo

- Após definir a categoria de base, categoria C, podemos explicar as chances com respeito a categoria de base usando variáveis explicativas.
- Isso é feito de forma equivalente a um MLG, ou seja,

$$\begin{aligned} log\left(\frac{\theta_A}{\theta_C}\right) &= \mathbf{x}^T\boldsymbol{\beta}^A \\ log\left(\frac{\theta_B}{\theta_C}\right) &= \mathbf{x}^T\boldsymbol{\beta}^B \end{aligned}$$

- Dessa forma, $\boldsymbol{\beta}^A$ e $\boldsymbol{\beta}^B$ são log ORs.



Estimando os βs

- Da equação anterior temos que

$$\frac{\theta_A}{\theta_C} = e^{\mathbf{x}^T\boldsymbol{\beta}^A}, \qquad \frac{\theta_B}{\theta_C} = e^{\mathbf{x}^T\boldsymbol{\beta}^B}$$

- Lembrando que $\theta_A + \theta_B + \theta_C = 1$.
- Pode-se mostrar que

$$\theta_C = \frac{1}{1 + e^{\mathbf{x}^T\boldsymbol{\beta}^A} + e^{\mathbf{x}^T\boldsymbol{\beta}^B}},$$

$$\theta_A = \frac{e^{\mathbf{x}^T\boldsymbol{\beta}^A}}{1 + e^{\mathbf{x}^T\boldsymbol{\beta}^A} + e^{\mathbf{x}^T\boldsymbol{\beta}^B}}, \qquad \theta_B = \frac{e^{\mathbf{x}^T\boldsymbol{\beta}^B}}{1 + e^{\mathbf{x}^T\boldsymbol{\beta}^A} + e^{\mathbf{x}^T\boldsymbol{\beta}^B}}$$

- Como podemos escrever os θs como função dos βs, podemos usar a função de probabilidade da multinomial para estimar os βs.



Estimando os βs

- A função de verossimilhança

$$P(\mathbf{Y} = \mathbf{y}|\boldsymbol{\theta}) = L(\boldsymbol{\beta}^A, \boldsymbol{\beta}^B; \mathbf{y})$$

- Como não temos um modelo linear generalizado, o método de estimação IWLS não é aplicável.
- No entanto, outros métodos de otimização podem ser usados. O pacote *nnet*, oferece uma solução para estimar os βs usando redes neurais (neural networks).
- Outro pacote que pode ser usado para estimação é o *mlogit*.
- Vamos usar o *nnet*, por ser mais simples de se usar.



Exemplo: Jacaré

- Replicando o exemplo anterior.
- Dieta de jacarés nos canais do recreio e Barra. 57 jacarés foram capturados, medidos e foi observado sua ultima alimentação.
- Os dados estão resumidos na tabela abaixo:

	Peixe	Inv.	Outro
Gde	16	8	8
Pq	5	15	5



Modelando no R

- Precisamos dos dados brutos (i.e. um indivíduo por linha)
- Defina para cada variável quem é a categoria de base.
  - O tipo de alimentação base será Invertebrados.
  - O tamanho base será pequeno.
- A regressão multinomial vai retornar as estimativas dos βs, que depois serão transformados em ORs



Saída do multinom

```
Call:
multinom(formula = Alimento ~ Tamanho, data = Jacare)

Coefficients:
    (Intercept) TamanhoG
Out   -1.098616 1.098615
Px    -1.098613 1.791758

Std. Errors:
    (Intercept)  TamanhoG
Out   0.5163983 0.7187956
Px    0.5163977 0.6739187

Residual Deviance: 114.0557
AIC: 122.0557
```



Saída mais informativa

```
> require('epicalc')
> mlogit.display(modelo)

Outcome =Alimento; Referent group = Inv
             Out                            Px
             Coeff./SE   RRR(95%CI)         Coeff./SE    RRR(95%CI)
(Intercept) -1.1/0.516* -                   -1.1/0.516*  -
TamanhoG     1.1/0.719   3(0.73,12.27)      1.79/0.674** 6(1.6,22.48)

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual Deviance: 114.06
AIC = 122.06
```



Exemplo: Preferências de opcionais no carro

- Em um estudo de segurança na direção realizado pela Universidade de Newcastle, Australia, em dezembro de 1997 e janeiro de 1998, homens e mulheres foram entrevistados e um das perguntas era para reponderem a importância do ar condicionado e direção hidráulica no carro.
- A descrição completa do dado, o questionário e os dados podem ser encontrados em `www.statsci.org/data/oz/carprefs.html`



Os dados resumidos

Importância do ar condicionado e direção hidráulica em carros.

		Resposta		
Sexo	Idade	Sem ou pouca importância	Importante	Muito importante
Homem	18-23	40	17	8
	24-40	17	15	12
	> 40	8	15	18
Mulher	18-23	26	12	7
	24-40	9	21	15
	> 40	5	14	41



O modelo ajustado

$$Resposta \sim faixa + sexo$$

```
Outcome =Resposta; Referent group = Sem ou pouca importancia
            Importante                      Muito importante
            Coeff./SE     RRR(95%CI)        Coeff./SE         RRR(95%CI)
(Intercept) -0.59/0.284*  -                 -1.04/0.331**     -
SexoHomem   -0.39/0.301   0.68(0.38,1.22)   -0.81/0.321*      0.44(0.24,0.83)
faixa24-40  1.13/0.342*** 3.09(1.58,6.04)   1.48/0.401***     4.38(2,9.62)
faixa> 40   1.59/0.403*** 4.89(2.22,10.78)  2.92/0.423***     18.48(8.07,42.34)

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual Deviance: 580.7
AIC = 596.7
```



Efeito do sexo

- O efeito do sexo (base Homem) ao compararmos os desfechos Importante x sem importância.

$$OR_I = 0.68$$

- O efeito do sexo (base Homem) ao compararmos os desfechos Muito importante x sem importância.

$$OR_M = 0.44 \rightarrow 1/OR_M = 2.27(1.20, 4.17)$$



Calculando as probabilidades

- Podemos vizualizar as proporções das respostas por faixa etária e sexo.
- Basta lembrar que

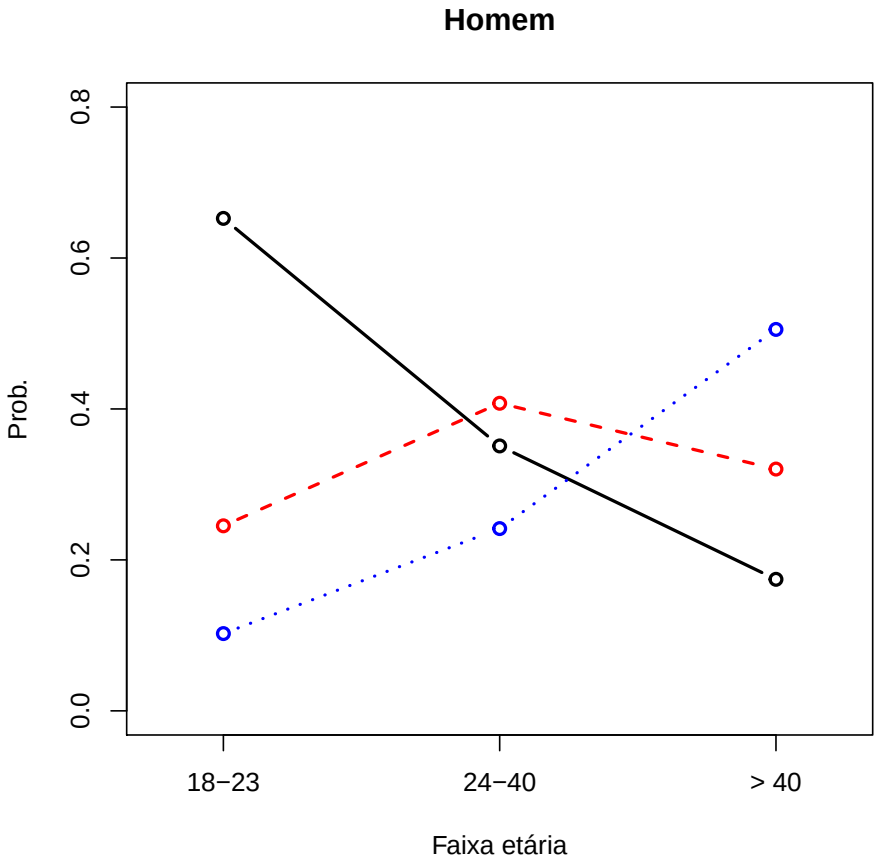
$$\theta_S = \frac{1}{1 + e^{\mathbf{x}^T\beta^I} + e^{\mathbf{x}^T\beta^M}},$$

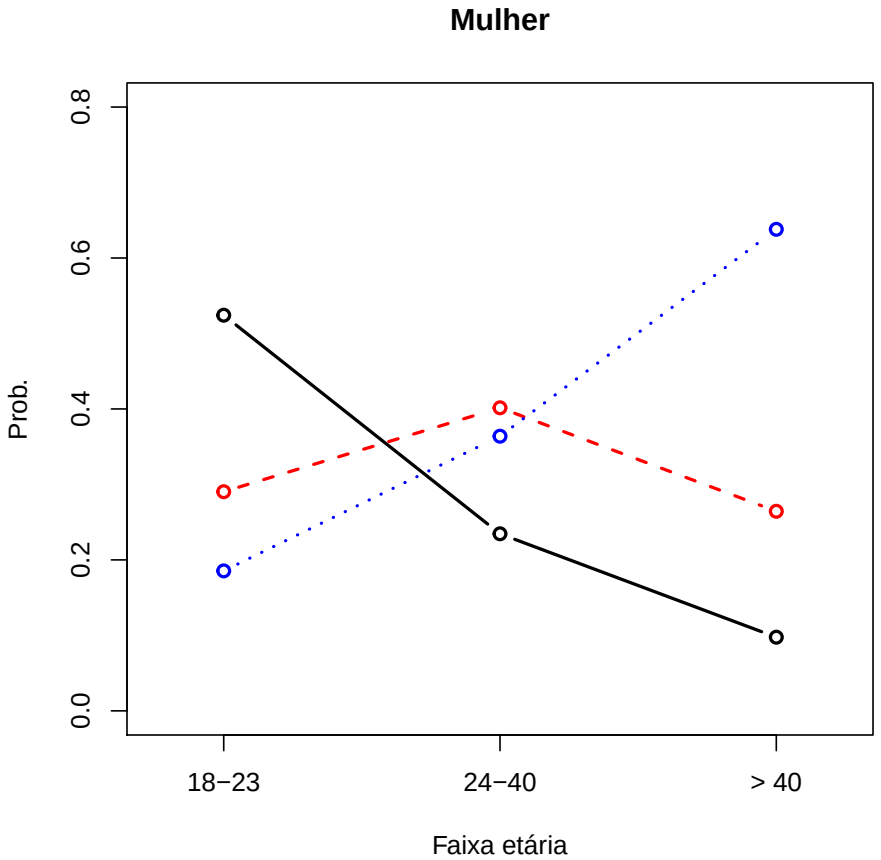
$$\theta_I = \frac{e^{\mathbf{x}^T\beta^I}}{1 + e^{\mathbf{x}^T\beta^I} + e^{\mathbf{x}^T\beta^M}}, \qquad \theta_M = \frac{e^{\mathbf{x}^T\beta^M}}{1 + e^{\mathbf{x}^T\beta^I} + e^{\mathbf{x}^T\beta^M}}$$

  onde S sem ou nenhuma importância, I importante e M muito importante.
- $\mathbf{x}^T\beta^k = \beta_0^k + \beta_1^k Sexo : Homem + \beta_2^k faixa : 24 - 40 + \beta_3^k faixa :> 40$



Preferência por AC e DH







Resumindo: Modelos multinomiais

- Os modelos multinomiais são usados quando a variável resposta é uma variável categórica com mais que dois níveis.
- Se fossem dois níveis, teríamos uma regressão binária (logística) usual.
- As razões de chances dependem da categoria de base do desfecho, levado isso em conta, a interpretação é essencialmente a mesma da regressão logística.
- Existe análise de resíduo para o modelo multinomial, e é similar a de modelos de regressão binária.



Dados ordinais

- Suponha agora que além de termos um desfecho categórico, os desfechos seguem uma ordenação natural.
- Exemplos:
  - Peso: {Normal, sobrepeso, obeso}
  - Opinião: {Discordo fortemente, discordo, nem concordo nem dscordo, concordo, concordo fortemente}
  - Notas: {A,B,C,D}
  - etc.
- Os modelos multinomiais podem ser aplicados normalmente, porém a informação da ordenação é ignorada.
- Os modelos logistico ordinais tentam incorporar a informação da ordenação das categorais no processo de inferência.



Modelos logísticos ordinais

- Suponha que temos J categorias, $C_1 < C_2 < \cdots < C_J$
- Modelo logístico acumulativo

$$\log\left(\frac{P(Y \leq C_j)}{P(Y > C_j)}\right) = \log\left(\frac{\theta_1 + \theta_2 + \cdots + \theta_j}{\theta_{j+1} + \cdots + \theta_J}\right) = \mathbf{x}^T\boldsymbol{\beta}^j$$

- Modelo logístico adjacente

$$\log\left(\frac{P(Y = C_j)}{P(Y = C_{j-1})}\right) = \log\left(\frac{\theta_j}{\theta_{j-1}}\right) = \mathbf{x}^T\boldsymbol{\beta}^j$$



Modelos logísticos ordinais

- Uma suposição bastante comum em softwares estatísticos, é a suposição de *odds* proporcionais.
- As variáveis explicativas não dependem da variável resposta, somente o intercepto é alterado.
- Modelo logístico acumulativo

$$\log\left(\frac{\theta_1 + \cdots + \theta_j}{\theta_{j+1} + \cdots + \theta_J}\right) = \beta_{0j} + x_1\beta_1 + \cdots + x_p\beta_p$$

- Modelo logístico adjacente

$$\log\left(\frac{\theta_j}{\theta_{j-1}}\right) == \beta_{0j} + x_1\beta_1 + \cdots + x_p\beta_p$$



Modelo logístico acumulativo com *odds* proporcionais

- A função *polr* da biblioteca *MASS* do R ajusta o modelo logístico acumulativo com *odds* proporcionais.
- Os comandos são similares ao *lm*, *glm*

```
> require(MASS)
> fit = polr(formula, data)
```

- Vamos rodar para o exemplo da importância do AC e DH.



Os dados resumidos

Importância do ar condicionado e direção hidráulica em carros.

		Resposta		
Sexo	Idade	Sem ou pouca importância	Importante	Muito importante
Mulher	18-23	40	17	8
	24-40	17	15	12
	>40	8	15	18
Homem	18-23	26	12	7
	24-40	9	21	15
	>40	5	14	41



O modelo ajustado

$$Resposta \sim faixa + sexo$$

```
Call:
polr(formula = Resposta ~ Sexo + faixa, data = carros)

Coefficients:
             Value Std. Error t value
SexoHomem  -0.5762     0.2262  -2.548
faixa24-40  1.1471     0.2776   4.132
faixa> 40   2.2325     0.2915   7.659

Intercepts:
                                    Value   Std. Error t value
Sem ou pouca importancia|Importante  0.0435  0.2323     0.1874
Importante|Muito importante          1.6550  0.2556     6.4744

Residual Deviance: 581.2956
AIC: 591.2956
```



Efeito do sexo

- O efeito do sexo (base Homem) ao compararmos os desfechos Sem importância x {Importante ou Muito Importante} (que por definição é o mesmo que comparar os desfechos {Sem importância ou Importante} versus Muito importante)

$$OR = \exp -0.5762 \rightarrow 1/OR = 1.779(1.143, 2.777)$$

- Para o modelo multinomial os efeitos do sexo foram:

$$1/OR_I = 1.47(0.82, 2.63) \qquad 1/OR_M = 2.27(1.20, 4.17)$$



Resumindo: Modelos ordinais

- Os modelos ordinais são usados quando a variável resposta é uma variável categórica com mais que dois níveis e os níveis tem uma ordenação natural.
- Existem vários modelos ordinais, jo mais usual assume *odds* proporcionais.
- A função *polr* ajusta o modelo ordinal acumulativo com odds proporcionais.



Exemplo: Método contraceptivo

Suponha um estudo com 3099 mulheres em idade fértil categorizadas por faixa etária sobre a utilização de método contraceptivo.

	Método		
Faixa	Esteril.	Nenhum	Outro
15-19	2	90	75
20-24	32	280	223
25-29	147	237	296
30-34	298	207	197
35-39	276	196	96
40-44	202	174	71

