

Lista 2: Modelos estatísticos

Leo Bastos (Impa Tech)

1. Seja a seguinte saída de um modelo linear, escrito informalmente como $Y \sim 1 + X_1 + X_2$, onde X_1 é uma variável contínua e X_2 uma variável categoria com 3 níveis (A, B e C). Uma amostra $\{(Y_i, X_{1,i}, X_{2,i})\}$, $i = 1, 2, \dots, n = 100$ foi coletado e seguinte modelo foi ajustado:

Table 1: Estimativas do modelo linear para 100 observações simuladas.

Characteristic	Beta	95% CI	p-value
x1	2.0	1.7, 2.4	<0.001
x2			
A	—	—	
B	-0.86	-1.2, -0.50	<0.001
C	1.9	1.7, 2.2	<0.001

Abbreviation: CI = Confidence Interval

- i. Escreva a equação do modelo
 - ii. Interpre os coeficientes em termos de valor esperado para o desfecho Y .
 - iii. Quais são as suposições do modelo para que possamos fazer inferência a respeito dos parâmetros do modelo?
 - iv. Uma nova observação vai ser realizada com $X_1 = 0.5$ e $X_2 = B$, qual o valor predito? Podemos calcular um intervalo? Se sim, calcule. Se não, diga o que falta para calcular.
 - v. Suponha que queremos testar $H_0 : \beta_1 = 1$ versus $H_A : \beta_1 \neq 1$. Podemos realizar tal teste? Se sim, faça. Se não, diga o que falta para realizar o teste.
2. Mostre que os resíduos, definidos por $\hat{e} = y - X\hat{\beta}$, não são independentes.
 3. Considere um modelo linear $Y = X\beta + e$, com $e \sim N_n(0, \sigma^2 I_n)$ e variância σ^2 conhecida. Mostre que usando uma priori imprópria $p(\beta) \propto 1$ leva a uma posteriori Normal p -variada com média $b = (X^T X)^{-1} X^T Y$ e matriz de variâncias $V_B = \sigma^2 (X^T X)^{-1}$.

4. Regressão segmentada. Suponha que estamos a avaliando o volume de produção de um determinado produto, Y , segundo a temperatura média da região, T . Sabe-se que sob condições ótimas de temperatura $T \in (t_1, t_2)$, a produção é estável, enquanto para temperaturas menores que t_1 ou maiores que t_2 a produção cai linearmente. Suponha que temos uma base de dados de uma região contendo n medidas de volume de produção e sua respectiva temperatura média, ou seja $(Y_1, T_1), (Y_2, T_2), \dots, (Y_n, T_n)$, com n_1 observações com temperaturas médias menores que t_1 , n_2 observações com temperaturas médias maiores que t_2 , e $n_3 = n - n_1 - n_2$ observações dentro da condição ótima de temperatura.
- Esboce um gráfico da produção Y e temperatura T .
 - Assuma que t_1 e t_2 são conhecidos e proponha um modelo estatístico que forneça a média do volume de produção no período ótimo, e quantifique as taxas de queda no volume de produção fora do período ótimo de produção.
 - Se t_1 e t_2 forem desconhecidos, como podemos fazer inferência para estimar média do volume de produção no período ótimo e as taxas de queda fora do período ótimo?
5. Agregador de pesquisas. Como podemos usar um modelo linear para estimar a proporção de votos de um candidato a presidente da república no dia da eleição usando dados de pesquisas eleitorais? Quais as limitações e suposições envolvidas?
6. Proponha um roteiro de análise de dados usando um modelo linear para explicar o comportamento de uma variável resposta Y . Partindo de um banco organizado com n observações, uma variável resposta Y e p variáveis explicativas.
7. Quais são os principais problemas ao ajustar um modelo linear quando a resposta é binária?