

Modelo logístico

Leo Bastos

leonardo.bastos{@fiocruz.br; @impatech.edu.br}

Impa Tech

<https://github.com/lb Bastos/md32>

Regressão logística múltipla

- O modelo logístico multivariado múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i),$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).

Regressão logística múltipla

- O modelo logístico multivariado múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i),$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).

Regressão logística múltipla

- O modelo logístico multivariado múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i),$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).

Regressão logística múltipla

- O modelo logístico multivariado múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i),$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k \Rightarrow \frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b\beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k \Rightarrow \frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b\beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$

Exemplo: Fumo na gestação versus baixo peso

- Em um estudo observacional sobre tabagismo na gestação realizado em um certo hospital, uma amostra de 189 puérperas foi aleatoriamente selecionada.
- Foi verificado se as mulheres fumaram ou não durante a gestação.
- o peso do recém nascido foi registrado, e categorizado como baixo peso sim ou não.
- Os dados observados foram

Fumou durante a gestação?	Baixo peso ao nascer?	
	Sim	Não
Sim	30	44
Não	29	86

Exemplo: Fumo na gestação versus baixo peso

- Em um estudo observacional sobre tabagismo na gestação realizado em um certo hospital, uma amostra de 189 puérperas foi aleatoriamente selecionada.
- Foi verificado se as mulheres fumaram ou não durante a gestação.
- o peso do recém nascido foi registrado, e categorizado como baixo peso sim ou não.
- Os dados observados foram

Fumou durante a gestação?	Baixo peso ao nascer?	
	Sim	Não
Sim	30	44
Não	29	86

Exemplo: Fumo na gestação versus baixo peso

- Em um estudo observacional sobre tabagismo na gestação realizado em um certo hospital, uma amostra de 189 puérperas foi aleatoriamente selecionada.
- Foi verificado se as mulheres fumaram ou não durante a gestação.
- o peso do recém nascido foi registrado, e categorizado como baixo peso sim ou não.
- Os dados observados foram

Fumou durante a gestação?	Baixo peso ao nascer?	
	Sim	Não
Sim	30	44
Não	29	86

Exemplo: Fumo na gestação versus baixo peso

- Em um estudo observacional sobre tabagismo na gestação realizado em um certo hospital, uma amostra de 189 puérperas foi aleatoriamente selecionada.
- Foi verificado se as mulheres fumaram ou não durante a gestação.
- o peso do recém nascido foi registrado, e categorizado como baixo peso sim ou não.
- Os dados observados foram

Fumou durante a gestação?	Baixo peso ao nascer?	
	Sim	Não
Sim	30	44
Não	29	86

- Quem é o desfecho, Y ?
- Quem é a variável explicativa, X ?
- Como é o modelo?

$$Y_i \mid X_i = x_i \sim \text{Bernoulli}(\theta_i)$$

onde $\text{logit}(\theta_i) = \alpha + \beta x_i$, $i = 1, 2, \dots, n$.

Construindo o modelo

- Quem é o desfecho, Y ?
- Quem é a variável explicativa, X ?
- Como é o modelo?

$$Y_i \mid X_i = x_i \sim \text{Bernoulli}(\theta_i)$$

onde $\text{logit}(\theta_i) = \alpha + \beta x_i, i = 1, 2, \dots, n.$

- Quem é o desfecho, Y ?
- Quem é a variável explicativa, X ?
- Como é o modelo?

$$Y_i \mid X_i = x_i \sim \text{Bernoulli}(\theta_i)$$

onde $\text{logit}(\theta_i) = \alpha + \beta x_i, i = 1, 2, \dots, n.$

- No R, usamos a função *glm*

```
> saida <- glm(low ~ smoke,  
+              family=binomial(link = 'logit'),  
+              data=birth)
```

- Precisamos especificar a família, nesse caso é a Binomial (Lembrem-se que a $Bernoulli(\theta) = Binomial(1, \theta)$)
- A função de ligação default é a logit.

Saída R: glm()

- A saída da função *glm* é bastante similar a saída da função *lm*
Call: `glm(formula = low ~ smoke, family = binomial(link = "logit"), data = birth)`

Coefficients:

(Intercept)	smokesim
-1.0871	0.7041

Degrees of Freedom: 188 Total (i.e. Null); 187 Residual

Null Deviance: 234.7

Residual Deviance: 229.8 AIC: 233.8

- Calculando a OR

```
> exp(0.7041)
```

```
[1] 2.022026
```

- As chances de um bebê com baixo peso para uma gestante fumante são 2,02 vezes as chances de baixo peso para uma gestante não fumante.

Saidas no R

Call:

```
glm(formula = low ~ smoke, family = binomial(link = "logit"),  
     data = birth)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.0871	0.2147	-5.062	4.14e-07	***
smokesim	0.7041	0.3196	2.203	0.0276	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 234.67 on 188 degrees of freedom
Residual deviance: 229.80 on 187 degrees of freedom
AIC: 233.8

Number of Fisher Scoring iterations: 4

- Lembrando que

$$\hat{\beta} \rightarrow N(\beta, F^{-1}(\beta))$$

- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
 - Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Podemos calcular um IC de 95% de confiança para a OR (ou para β)
 - Um IC de 95% para a OR é dado pela exponencial do intervalo de 95% para β .
 - Note que esse forma o intervalo para a OR não é mais simétrico em torno da estimativa pontual, mas continua sendo um IC de 95% válido.

- Lembrando que

$$\hat{\beta} \rightarrow N(\beta, F^{-1}(\beta))$$

- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
 - Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Podemos calcular um IC de 95% de confiança para a OR (ou para β)
 - Um IC de 95% para a OR pode ser calculado calculando o IC de 95% para β e exponenciando.
 - Note que esse intervalo de confiança para a OR não é mais simétrico em torno da OR estimada porque a distribuição de β não é simétrica em torno de zero.

- Lembrando que

$$\hat{\beta} \rightarrow N(\beta, F^{-1}(\beta))$$

- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
 - Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Podemos calcular um IC de 95% de confiança para a OR (ou para β)
 - Um IC de 95% para a OR é dado pela exponencial do intervalo de 95% para β .
 - Assim, qual é o intervalo de 95% para a OR, isto é, qual é o intervalo de 95% para $\exp(\beta)$?

- Lembrando que

$$\hat{\beta} \rightarrow N(\beta, F^{-1}(\beta))$$

- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
 - Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Podemos calcular um IC de 95% de confiança para a OR (ou para β)
 - Um IC de 95% para a OR é dado pela exponencial do intervalo de 95% para β .
 - Note que dessa forma o intervalo para a OR não é mais simétrico em torno da estimativa pontual, mas continua sendo um IC de 95% válido.

- Lembrando que

$$\hat{\beta} \rightarrow N(\beta, F^{-1}(\beta))$$

- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
 - Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Podemos calcular um IC de 95% de confiança para a OR (ou para β)
 - Um IC de 95% para a OR é dado pela exponencial do intervalo de 95% para β .
 - Note que dessa forma o intervalo para a OR não é mais simétrico em torno da estimativa pontual, mas continua sendo um IC de 95% válido.

- Lembrando que

$$\hat{\beta} \rightarrow N(\beta, F^{-1}(\beta))$$

- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
 - Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Podemos calcular um IC de 95% de confiança para a OR (ou para β)
 - Um IC de 95% para a OR é dado pela exponencial do intervalo de 95% para β .
 - Note que dessa forma o intervalo para a OR não é mais simétrico em torno da estimativa pontual, mas continua sendo um IC de 95% válido.

- O IC para os coeficientes podemos ser calculados da seguinte forma

```
> cbind(saida$coef, confint(saida) )
```

		2.5 %	97.5 %
(Intercept)	-1.0870515	-1.5243118	-0.679205
smokesim	0.7040592	0.0786932	1.335154

- E o IC para o coeficiente é dado por

```
> exp(cbind(OR=saida$coef, confint(saida) ))[-1,]
```

	OR	2.5 %	97.5 %
	2.021944	1.081872	3.800582

Função logística

- Se for de interesse (e o delineamento do estudo permitir) podemos estimar a probabilidade do desfecho ocorrer sob condições específicas das variáveis explicativas.

- Ou seja,

$$P(Y_i = 1|X = x) = \text{logit}^{-1}(\alpha + \beta x)$$

- Para o modelo logístico:

$$P(Y_i = 1|X = x) = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$$

- Logo, previsões para essas probabilidades são dados por

$$\hat{P}(Y_i = 1|X = x) = \frac{e^{\hat{\alpha} + \hat{\beta} x}}{1 + e^{\hat{\alpha} + \hat{\beta} x}}$$

Função logística

- Se for de interesse (e o delineamento do estudo permitir) podemos estimar a probabilidade do desfecho ocorrer sob condições específicas das variáveis explicativas.
- Ou seja,

$$P(Y_i = 1|X = x) = \text{logit}^{-1}(\alpha + \beta x)$$

- Para o modelo logístico:

$$P(Y_i = 1|X = x) = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$$

- Logo, previsões para essas probabilidades são dados por

$$\hat{P}(Y_i = 1|X = x) = \frac{e^{\hat{\alpha} + \hat{\beta}x}}{1 + e^{\hat{\alpha} + \hat{\beta}x}}$$

Função logística

- Se for de interesse (e o delineamento do estudo permitir) podemos estimar a probabilidade do desfecho ocorrer sob condições específicas das variáveis explicativas.
- Ou seja,

$$P(Y_i = 1|X = x) = \text{logit}^{-1}(\alpha + \beta x)$$

- Para o modelo logístico:

$$P(Y_i = 1|X = x) = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$$

- Logo, previsões para essas probabilidades são dados por

$$\hat{P}(Y_i = 1|X = x) = \frac{e^{\hat{\alpha} + \hat{\beta}x}}{1 + e^{\hat{\alpha} + \hat{\beta}x}}$$

- Se for de interesse (e o delineamento do estudo permitir) podemos estimar a probabilidade do desfecho ocorrer sob condições específicas das variáveis explicativas.
- Ou seja,

$$P(Y_i = 1|X = x) = \text{logit}^{-1}(\alpha + \beta x)$$

- Para o modelo logístico:

$$P(Y_i = 1|X = x) = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$$

- Logo, previsões para essas probabilidades são dados por

$$\hat{P}(Y_i = 1|X = x) = \frac{e^{\hat{\alpha} + \hat{\beta}x}}{1 + e^{\hat{\alpha} + \hat{\beta}x}}$$

No exemplo

- No exemplo, podemos estimar a probabilidade de bebê com baixo peso para mulheres que fumam e para mulheres que não fumam durante a gravidez.
- Basta usar a função *predict*

```
> birth.pred <- data.frame(smoke = c("sim", "nao"))  
> prev <- predict(saida, type = 'response',  
+                 newdata = birth.pred)  
> prev
```

	1	2
	0.4054054	0.2521739

Intervalo de confiança para a previsão

- Para evitar 'esquisitices' o intervalo de confiança para as previsões exigem um pouco mais de algebrismo.

```
> prev2 <- predict(saida, type = 'link',  
+                  newdata = birth.pred,  
+                  se.fit = T)
```

- Criando os intervalos

```
> birth.pred <- birth.pred %>%  
+   bind_cols(  
+     Prob = prev,  
+     Link = prev2$fit,  
+     Link.sd = prev2$se.fit  
+   )
```

- A tabela estimada:

	smoke	Prob	Link	Link.sd
1	sim	0.405	-0.383	0.237
2	nao	0.252	-1.087	0.215

- IC para $\eta = \alpha + \beta x$

	smoke	Link	Link.sd	LI	LS
1	sim	-0.383	0.237	-0.847	0.081
2	nao	-1.087	0.215	-1.508	-0.666

- IC para $\theta_x = \text{logit}^{-1}(\alpha + \beta x)$

	smoke	Prob	LI	LS
1	sim	0.405	0.300	0.520
2	nao	0.252	0.181	0.339

- A tabela estimada:

	smoke	Prob	Link	Link.sd
1	sim	0.405	-0.383	0.237
2	nao	0.252	-1.087	0.215

- IC para $\eta = \alpha + \beta x$

	smoke	Link	Link.sd	LI	LS
1	sim	-0.383	0.237	-0.847	0.081
2	nao	-1.087	0.215	-1.508	-0.666

- IC para $\theta_x = \text{logit}^{-1}(\alpha + \beta x)$

	smoke	Prob	LI	LS
1	sim	0.405	0.300	0.520
2	nao	0.252	0.181	0.339

- A tabela estimada:

	smoke	Prob	Link	Link.sd
1	sim	0.405	-0.383	0.237
2	nao	0.252	-1.087	0.215

- IC para $\eta = \alpha + \beta x$

	smoke	Link	Link.sd	LI	LS
1	sim	-0.383	0.237	-0.847	0.081
2	nao	-1.087	0.215	-1.508	-0.666

- IC para $\theta_x = \text{logit}^{-1}(\alpha + \beta x)$

	smoke	Prob	LI	LS
1	sim	0.405	0.300	0.520
2	nao	0.252	0.181	0.339

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.

Exemplo: Sífilis em usuários de drogas

```
> dados <- read.csv("../dados/DUsifilis.csv")  
> head(dados)
```

	sifilis	sexo	idade	faixaetaria
1	0	masculino	46	35 a 49 anos
2	0	masculino	29	25 a 34 anos
3	0	masculino	44	35 a 49 anos
4	0	masculino	20	18 a 24 anos
5	0	masculino	26	25 a 34 anos
6	0	masculino	39	35 a 49 anos

- *Sifilis* $\sim$ *Sexo*

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7975	0.1703	-4.68	0.0000
sexomasculino	-0.5443	0.2067	-2.63	0.0084

- $OR_{Sexo:Masculino} = 0.58$. (Qual a interpretação?)

- $Sifilis \sim Sexo$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7975	0.1703	-4.68	0.0000
sexomasculino	-0.5443	0.2067	-2.63	0.0084

- $OR_{Sexo:Masculino} = 0.58$. (Qual a interpretação?)

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois $OR_{Sexo: Masc} = 1/OR_{Sexo: Fem}$ (É mesmo?)
- E portanto, $OR_{Sexo: Fem} = 1/OR_{Sexo: Masc} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo: Fem} = 1/OR_{Sexo: Masc} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois
$$OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino} \text{ (É mesmo?)}$$
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois
$$OR_{Sexo: Masc} = 1/OR_{Sexo: Fem} \text{ (É mesmo?)}$$
- E portanto, $OR_{Sexo: Fem} = 1/OR_{Sexo: Masc} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo: Fem} = 1/OR_{Sexo: Masc} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.

- $Sifilis \sim Sexo + faixaetaria$

```
> m1Sex <- glm(sifilis ~ sexo + faixaetaria,  
+              dados, family=binomial())  
> xtable(m1Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.0659	0.2463	-8.39	0.0000
sexofeminino	0.7422	0.2183	3.40	0.0007
faixaetaria25 a 34 anos	0.6171	0.2781	2.22	0.0265
faixaetaria35 a 49 anos	1.0353	0.2858	3.62	0.0003
faixaetaria50 anos ou mais	1.1607	0.3646	3.18	0.0015

- $OR_{Sexo:Fem} = 2.1$

- $Sifilis \sim Sexo + Idade$

```
> m2Sex <- glm(sifilis ~ sexo + idade,  
+             dados, family=binomial())  
> xtable(m2Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.5044	0.3490	-7.17	0.0000
sexofeminino	0.7342	0.2170	3.38	0.0007
idade	0.0329	0.0090	3.66	0.0003

- $OR_{Sexo:Fem} = 2.08$

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			604	659.34	
sexo	1	6.76	603	652.58	0.0093
faixaetaria	3	16.95	600	635.63	0.0007

- AIC

$$AIC = -2l(\hat{\beta}) + 2p$$

onde $-2l(\hat{\beta}) = Deviance$ é a deviance ou função desvio.

- R^2 ajustado

$$R_{adj}^2 = 1 - \left(1 - \frac{(n-1) Deviance}{(n-p) Deviance_0} \right)$$

onde $Deviance_0$ é a deviance do modelo nulo (só com intercepto).

- AIC

$$AIC = -2l(\hat{\beta}) + 2p$$

onde $-2l(\hat{\beta}) = Deviance$ é a deviance ou função desvio.

- R^2 ajustado

$$R_{adj}^2 = 1 - \left(1 - \frac{(n-1) Deviance}{(n-p) Deviance_0} \right)$$

onde $Deviance_0$ é a deviance do modelo nulo (só com intercepto).

AIC e R^2 ajustado

```
> AIC(m0Sex, m1Sex, m2Sex)
```

	df	AIC
m0Sex	2	656.5810
m1Sex	5	645.6326
m2Sex	3	645.1537

```
> glmtoolbox::adjR2(m0Sex, m1Sex, m2Sex)
```

	Deviance	R-squared	df	adj.R-squared
m0Sex	652.5810	0.01025	2	0.00860
m1Sex	635.6326	0.03595	5	0.02952
m2Sex	639.1537	0.03061	3	0.02739

- Sexo e faixa etária não são colineares ($\text{GVIF} < 10$)

```
> car::vif( glm(sifilis ~ sexo + faixaetaria,  
+              dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo          1.08117  1          1.039793  
faixaetaria 1.08117  3          1.013092
```

Multicolinearidade: Idade e faixa etária juntos

```
> summary( glm(sifilis ~ sexo + idade + faixaetaria,  
+             dados, family=binomial()) )
```

```
Call:  
glm(formula = sifilis ~ sexo + idade + faixaetaria, family = binomial(),  
    data = dados)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-2.099655	0.674332	-3.114	0.001848	**
sexofeminino	0.742434	0.218369	3.400	0.000674	***
idade	0.001634	0.030354	0.054	0.957058	
faixaetaria25 a 34 anos	0.602956	0.382346	1.577	0.114798	
faixaetaria35 a 49 anos	1.002031	0.681217	1.471	0.141307	
faixaetaria50 anos ou mais	1.106114	1.077052	1.027	0.304429	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 659.34 on 604 degrees of freedom
Residual deviance: 635.63 on 599 degrees of freedom
AIC: 647.63

Number of Fisher Scoring iterations: 4

- Calculando o GVIF

```
> car::vif( glm(sifilis ~ sexo + idade + faixaetaria,  
+              dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo           1.081758 1           1.040076  
idade          11.487130 1           3.389267  
faixaetaria 11.532768 3           1.503104
```

	OR	2.5 %	97.5 %
Bruto	1.72	1.15	2.58
Ajustado por faixa etária	2.10	1.37	3.22
Ajustado por idade	2.08	1.36	3.19

Tabela: Efeito do sexo (Base: Masculino) no log da chance de infecção por sífilis

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:

1. Particionar os possíveis valores de probabilidade em g grupos (Ex: 10% cada).

2. Para cada grupo, contar quantos casos foram observados e quantos foram previstos, dentro daquele grupo.

3. Para cada grupo, tem-se um teste de χ^2 .

4. Se o valor crítico exceder as irregularidades das observações, então o modelo não se ajusta bem.

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:

- Particionar os possíveis valores de probabilidade em g grupos (Ex. decís)

• Para cada grupo, calcular a probabilidade esperada de ocorrência de cada resultado, considerando a distribuição de probabilidade esperada para cada grupo.

• Comparar a probabilidade observada de ocorrência de cada resultado com a probabilidade esperada de ocorrência de cada resultado.

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decis).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decis).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decis).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decis).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decís).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.

- Estatística de bondade de ajuste de Hosmer-Lemeshow, $\hat{C}$

$$\hat{C} = \sum_{k=1}^g \frac{(o_k - n'_k \bar{\pi}_k)^2}{n'_k \bar{\pi}_k (1 - \bar{\pi}_k)}$$

onde g é o número de grupos, n'_k número de observações no grupo k , o_k número de casos observados no grupo k , e $\bar{\pi}_k$ é média das probabilidade estimada no grupo k .

- $\hat{C} \rightarrow \chi^2_{g-2}$

- Estatística de bondade de ajuste de Hosmer-Lemeshow, $\hat{C}$

$$\hat{C} = \sum_{k=1}^g \frac{(o_k - n'_k \bar{\pi}_k)^2}{n'_k \bar{\pi}_k (1 - \bar{\pi}_k)}$$

onde g é o número de grupos, n'_k número de observações no grupo k , o_k número de casos observados no grupo k , e $\bar{\pi}_k$ é média das probabilidade estimada no grupo k .

- $\hat{C} \rightarrow \chi^2_{g-2}$

Exemplo: Teste Hosmer-Lemeshow

Para o exemplo da sífilis, sexo e faixa etária geram 8 grupos, então $g = 8$

	Grupo	O_k	n'_k	$\hat{\theta}_k$	E_k
1	masculino : 18 a 24 anos	13	105	0.11	11.81
2	masculino : 25 a 34 anos	24	143	0.19	27.20
3	masculino : 35 a 49 anos	37	138	0.26	36.29
4	masculino : 50 anos ou mais	18	58	0.29	16.70
5	feminino : 18 a 24 anos	11	58	0.21	12.19
6	feminino : 25 a 34 anos	25	66	0.33	21.80
7	feminino : 35 a 49 anos	13	32	0.43	13.71
8	feminino : 50 anos ou mais	1	5	0.46	2.30

$$\hat{C} = 3.03 \rightarrow \text{p-valor} = 0.806$$

Teste Hosmer-Lemeshow no R

```
> glmtoolbox::hltest(m1Sex)
```

The Hosmer-Lemeshow goodness-of-fit test

Group	Size	Observed	Expected
1	105	13	11.808265
2	143	24	27.197188
3	58	11	12.191735
4	138	37	36.291221
5	58	18	16.703326
6	66	25	21.802812
7	32	13	13.708779
8	5	1	2.296674

Statistic = 3.02556

degrees of freedom = 6

p-value = 0.80563

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.

Outliers ou pontos influentes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:

- DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{(i)}$

- DFBETAS: Diferença no parâmetro de regressão de cada variável: $\hat{\beta}_j - \hat{\beta}_{j(i)}$

- Cook's Distance: Diferença no vetor de parâmetros: $\hat{\beta} - \hat{\beta}_{(i)}$

- Leverage (pontos de alavanca): h_{ii} ($\text{hatvalues}(\text{modelo})$)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes

Outliers: Medidas de influência

```
> summary(influence.measures(m1Sex))
```

Potentially influential observations of

```
glm(formula = sifilis ~ sexo + faixaetaria, family = binomial(),
```

data

	dfb.1_	dfb.sxfrm	dfb.fa3a	dfb.fa4a	dfb.faom	dffit	cov.r	cook.d	hat
103	-0.05	0.12	0.01	0.02	0.16	0.21	1.03_*	0.01	0.03_*
104	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
143	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
384	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
560	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03 *	0.01	0.03 *



- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Podemos explicar a probabilidade de sobreviver segundo sexo e idade
- Podemos comparar as probabilidades (ou avaliar as ORs) associadas a sobrevivência entre os sexos, e entre os dois grupos de idade.
- Então, basta calcularmos as ORs

$$OR_{Sex:Female} = \frac{Odds(Female)}{Odds(Male)}$$

e

$$OR_{Age:Child} = \frac{Odds(Child)}{Odds(Adult)}$$

- Podemos explicar a probabilidade de sobreviver segundo sexo e idade
- Podemos comparar as probabilidades (ou avaliar as ORs) associadas a sobrevivência entre os sexos, e entre os dois grupos de idade.
- Então, basta calcularmos as ORs

$$OR_{Sex:Female} = \frac{Odds(Female)}{Odds(Male)}$$

e

$$OR_{Age:Child} = \frac{Odds(Child)}{Odds(Adult)}$$

- Podemos explicar a probabilidade de sobreviver segundo sexo e idade
- Podemos comparar as probabilidades (ou avaliar as ORs) associadas a sobrevivência entre os sexos, e entre os dois grupos de idade.
- Então, basta calcularmos as ORs

$$OR_{Sex:Female} = \frac{Odds(Female)}{Odds(Male)}$$

e

$$OR_{Age:Child} = \frac{Odds(Child)}{Odds(Adult)}$$

Lendo os dados no R

- Chamando o banco

```
> data("Titanic")
> Titanic2 <- Titanic |> as_tibble() |>
+   pivot_wider(names_from = Survived, values_from = n)
> head(Titanic2, n = 5)
```

```
# A tibble: 5 × 5
```


	Class	Sex	Age	No	Yes
	<chr>	<chr>	<chr>	<dbl>	<dbl>
1	1st	Male	Child	0	5
2	2nd	Male	Child	0	11
3	3rd	Male	Child	35	13
4	Crew	Male	Child	0	0
5	1st	Female	Child	0	1

Definindo categorias de base

- Transformando em fatores e definindo categorias de base

```
> Titanic2 <- Titanic2 |>  
+   mutate(  
+     Sex = factor(Sex) |> relevel(ref = "Male"),  
+     Age = factor(Age) |> relevel(ref = "Adult"),  
+     Class = factor(Class) |> relevel(ref = "Crew")  
+   )
```

Visualizando: Sobrevivência por sexo



- Tabela para Sexo

	Sex	Surv:Yes	Surv:No
1	Male	367	1364
2	Female	344	126

- $OR_{Sex:Female} = \frac{1364*344}{367*126} = 10.15$
- As chances de uma mulher sobreviver ao naufrágio são 10.15 vezes as chances de um homem sobreviver.

- Tabela para Sexo

	Sex	Surv:Yes	Surv:No
1	Male	367	1364
2	Female	344	126

- $OR_{Sex:Female} = \frac{1364 \cdot 344}{367 \cdot 126} = 10.15$


- As chances de uma mulher sobreviver ao naufrágio são 10.15 vezes as chances de um homem sobreviver.

- Tabela para Sexo

	Sex	Surv:Yes	Surv:No
1	Male	367	1364
2	Female	344	126

- $OR_{Sex:Female} = \frac{1364*344}{367*126} = 10.15$
- As chances de uma mulher sobreviver ao naufrágio são 10.15 vezes as chances de um homem sobreviver.

Visualizando: Sobrevivência por idade



- Tabela para Sexo

	Age	Surv:Yes	Surv:No
1	Adult	654	1438
2	Child	57	52

- $OR_{Age:Child} = \frac{57*1438}{52*654} = 2.41$
- As chances de uma criança sobreviver ao naufrágio são 2.41 vezes as chances de um adulto sobreviver.

- Tabela para Sexo

	Age	Surv:Yes	Surv:No
1	Adult	654	1438
2	Child	57	52

- $OR_{Age:Child} = \frac{57 \cdot 1438}{52 \cdot 654} = 2.41$

- As chances de uma criança sobreviver ao naufrágio são 2.41 vezes as chances de um adulto sobreviver.

- Tabela para Sexo

	Age	Surv:Yes	Surv:No
1	Adult	654	1438
2	Child	57	52

- $OR_{Age:Child} = \frac{57 \cdot 1438}{52 \cdot 654} = 2.41$
- As chances de uma criança sobreviver ao naufrágio são 2.41 vezes as chances de um adulto sobreviver.

- O modelo logístico tem a forma

$$Y_i \sim \text{Ber}(\theta_i)$$

onde $Y_i = 1$ se o indivíduo sobreviveu, $g(\theta_i) = \alpha + \beta X_i$

- Se o dado estiver agregado, cada linha representa um conjunto de categorias, podemos escrever o modelo da seguinte forma
- O modelo logístico tem a forma

$$Z_k \sim \text{Bin}(n_k, \theta_k)$$

onde Z_k é o número de sobreviventes na linha k , n_k o número de passageiros na linha k , e $g(\theta_k) = \alpha + \beta X_k$

- O modelo logístico tem a forma

$$Y_i \sim \text{Ber}(\theta_i)$$

onde $Y_i = 1$ se o indivíduo sobreviveu, $g(\theta_i) = \alpha + \beta X_i$

- Se o dado estiver agregado, cada linha representa um conjunto de categorias, podemos escrever o modelo da seguinte forma
- O modelo logístico tem a forma

$$Z_k \sim \text{Bin}(n_k, \theta_k)$$

onde Z_k é o número de sobreviventes na linha k , n_k o número de passageiros na linha k , e $g(\theta_k) = \alpha + \beta X_k$

- O modelo logístico tem a forma

$$Y_i \sim \text{Ber}(\theta_i)$$

onde $Y_i = 1$ se o indivíduo sobreviveu, $g(\theta_i) = \alpha + \beta X_i$

- Se o dado estiver agregado, cada linha representa um conjunto de categorias, podemos escrever o modelo da seguinte forma
- O modelo logístico tem a forma

$$Z_k \sim \text{Bin}(n_k, \theta_k)$$

onde Z_k é o número de sobreviventes na linha k , n_k o número de passageiros na linha k , e $g(\theta_k) = \alpha + \beta X_k$

Olhando o dado agregado

- O dado em sua forma agregada

```
> head(Titanic2)
```

```
# A tibble: 6 × 5
```

	Class	Sex	Age	No	Yes
	<fct>	<fct>	<fct>	<dbl>	<dbl>
1	1st	Male	Child	0	5
2	2nd	Male	Child	0	11
3	3rd	Male	Child	35	13
4	Crew	Male	Child	0	0
5	1st	Female	Child	0	1
6	2nd	Female	Child	0	13

Modelos para dados agregados

```
> m0Sex <- glm(cbind(Yes, No) ~ Sex,  
+             data = Titanic2,  
+             family=binomial())  
> m0Age <- glm(cbind(Yes, No) ~ Age,  
+             data = Titanic2,  
+             family=binomial())
```

- $(Surv : Y, Surv : N) \sim Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3128	0.0588	-22.33	0.0000
SexFemale	2.3172	0.1196	19.38	0.0000

- $OR_{SexFemale} = 10.15$

- $(Surv : Y, Surv : N) \sim Age$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7879	0.0472	-16.71	0.0000
AgeChild	0.8797	0.1975	4.45	0.0000

- $OR_{Age:Child} = 2.41$

- $(Surv : Y, Surv : N) \sim Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3128	0.0588	-22.33	0.0000
SexFemale	2.3172	0.1196	19.38	0.0000

- $OR_{SexFemale} = 10.15$

- $(Surv : Y, Surv : N) \sim Age$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7879	0.0472	-16.71	0.0000
AgeChild	0.8797	0.1975	4.45	0.0000

- $OR_{Age:Child} = 2.41$

- $(Surv : Y, Surv : N) \sim Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3128	0.0588	-22.33	0.0000
SexFemale	2.3172	0.1196	19.38	0.0000

- $OR_{SexFemale} = 10.15$

- $(Surv : Y, Surv : N) \sim Age$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7879	0.0472	-16.71	0.0000
AgeChild	0.8797	0.1975	4.45	0.0000

- $OR_{Age:Child} = 2.41$

- $(Surv : Y, Surv : N) \sim Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3128	0.0588	-22.33	0.0000
SexFemale	2.3172	0.1196	19.38	0.0000

- $OR_{SexFemale} = 10.15$

- $(Surv : Y, Surv : N) \sim Age$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7879	0.0472	-16.71	0.0000
AgeChild	0.8797	0.1975	4.45	0.0000


- $OR_{Age:Child} = 2.41$

- Podemos encontrar as ORs ajustadas, i.e. a OR do sexo ajustada por idade, e a OR da idade ajustada pelo sexo.
- $(Surv : Y, Surv : N) \sim Age + Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3365	0.0599	-22.32	0.0000
SexFemale	2.2940	0.1199	19.13	0.0000
AgeChild	0.5564	0.2276	2.44	0.0145

- $OR_{SexFemale} = 9.91$ e $OR_{AgeChild} = 1.74$

Visualizando: Sobrevivência por idade e sexo



- $(Surv : Y, Surv : N) \sim Age$ (para os homens)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3691	0.0609	-22.47	0.0000
AgeChild	1.1811	0.2584	4.57	0.0000

- $(Surv : Y, Surv : N) \sim Age$ (para as mulheres)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.0644	0.1111	9.58	0.0000
AgeChild	-0.5654	0.3269	-1.73	0.0837

- $(Surv : Y, Surv : N) \sim Age$ (para os homens)

	Estimate	Std. Error	z value	$Pr(> z)$
(Intercept)	-1.3691	0.0609	-22.47	0.0000
AgeChild	1.1811	0.2584	4.57	0.0000

- $(Surv : Y, Surv : N) \sim Age$ (para as mulheres)

	Estimate	Std. Error	z value	$Pr(> z)$
(Intercept)	1.0644	0.1111	9.58	0.0000
AgeChild	-0.5654	0.3269	-1.73	0.0837

Criando uma categoria única Sexo e idade

- Agora vamos criar uma categoria para sexo e idade, vamos chamá-la de SexAge.
- $(Surv : Y, Surv : N) \sim AgeSex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3691	0.0609	-22.47	0.0000
AgeSexAdult:Female	2.4335	0.1267	19.21	0.0000
AgeSexChild:Female	1.8681	0.3134	5.96	0.0000
AgeSexChild:Male	1.1811	0.2584	4.57	0.0000

- Lembrando que podemos recuperar as probabilidades aplicando a função logit inversa,

$$\hat{\theta} = \text{logit}^{-1}\left(\alpha + \sum_i \text{AgeSex}_i \hat{\beta}_i\right)$$

- Resultando na tabela:

	Levels	OR	SurvProb	LI	LS
1	Adult:Male	1.000	0.203	0.184	0.223
2	Adult:Female	11.399	0.744	0.700	0.783
3	Child:Female	6.476	0.622	0.474	0.751
4	Child:Male	3.258	0.453	0.336	0.575

- Lembrando que podemos recuperar as probabilidades aplicando a função logit inversa,

$$\hat{\theta} = \text{logit}^{-1}\left(\alpha + \sum_i \text{AgeSex}_i \hat{\beta}_i\right)$$

- Resultando na tabela:

	Levels	OR	SurvProb	LI	LS
1	Adult:Male	1.000	0.203	0.184	0.223
2	Adult:Female	11.399	0.744	0.700	0.783
3	Child:Female	6.476	0.622	0.474	0.751
4	Child:Male	3.258	0.453	0.336	0.575

- Comparando modelos via AIC

	Modelos	AIC
1	1 + Age	703.02
2	1 + Sex	288.11
3	1 + Age + Sex	284.22
4	1 + AgeSex	269.90


Conclusão?

- E aí, Mulheres e crianças primeiro?
- Mulheres adultas primeiro, depois crianças!

Conclusão?

- E aí, Mulheres e crianças primeiro?
- Mulheres adultas primeiro, depois crianças!

Visualizando: Sobrevivência por classe



Modelo adicionando a Classe

- $(Surv : Y, Surv : N) \sim AgeSex + Class$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.2389	0.0807	-15.35	0.0000
AgeSexAdult:Female	2.6172	0.1510	17.33	0.0000
AgeSexChild:Female	2.5072	0.3332	7.52	0.0000
AgeSexChild:Male	1.7921	0.2829	6.33	0.0000
Class1st	0.8033	0.1598	5.03	0.0000
Class2nd	-0.2305	0.1771	-1.30	0.1932
Class3rd	-1.0072	0.1530	-6.58	0.0000

	OR	LI	LS
Class1st	2.23	1.63	3.05
Class2nd	0.79	0.56	1.12
Class3rd	0.37	0.27	0.49

- ORs por classe (Baseline: Crew)

	OR	LI	LS
Class1st	2.23	1.63	3.05
Class2nd	0.79	0.56	1.12
Class3rd	0.37	0.27	0.49

- ORs por Idade e sexo (Baseline: Adult:Male)

	OR.crude	OR.adj
AgeSexAdult:Female	11.40	13.70
AgeSexChild:Female	6.48	12.27
AgeSexChild:Male	3.26	6.00

- ORs por classe (Baseline: Crew)

	OR	LI	LS
Class1st	2.23	1.63	3.05
Class2nd	0.79	0.56	1.12
Class3rd	0.37	0.27	0.49

- ORs por Idade e sexo (Baseline: Adult:Male)

	OR.crude	OR.adj
AgeSexAdult:Female	11.40	13.70
AgeSexChild:Female	6.48	12.27
AgeSexChild:Male	3.26	6.00

- $(Surv : Y, Surv : N) \sim AgeSex$ (AIC = 269.9)
- $(Surv : Y, Surv : N) \sim AgeSex + Class$ (AIC = 155.2)

- ORs por classe (Baseline: Crew)

	OR	LI	LS
Class1st	2.23	1.63	3.05
Class2nd	0.79	0.56	1.12
Class3rd	0.37	0.27	0.49

- ORs por Idade e sexo (Baseline: Adult:Male)

	OR.crude	OR.adj
AgeSexAdult:Female	11.40	13.70
AgeSexChild:Female	6.48	12.27
AgeSexChild:Male	3.26	6.00

- $(Surv : Y, Surv : N) \sim AgeSex$ (AIC = 269.9)
- $(Surv : Y, Surv : N) \sim AgeSex + Class$ (AIC = 155.2)

Probabilidades de sobrevivência

