

Exemplos de análise de dados no modelo linear

Leo Bastos

leonardo.bastos{@fiocruz.br; @impatech.edu.br}

Impa Tech

<https://github.com/lsbastos/md32>

O modelo linear múltiplo

- Vamos assumir que temos duas ou mais variáveis explicativas.
- Seja Y um desfecho contínuo avaliado em n observações independentes, e de forma geral p variáveis explicativas X , ou seja,

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n,$$
$$\mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i}.$$

- Isso é o mesmo que escrever

$$Y_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i} + \epsilon_i$$

onde $\epsilon_i \sim N(0, \sigma^2)$, e $\epsilon_i \perp \epsilon_j, \forall i \neq j$.

O modelo linear múltiplo

- Vamos assumir que temos duas ou mais variáveis explicativas.
- Seja Y um desfecho contínuo avaliado em n observações independentes, e de forma geral p variáveis explicativas X , ou seja,

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n,$$
$$\mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i}.$$

- Isso é o mesmo que escrever

$$Y_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i} + \epsilon_i$$

onde $\epsilon_i \sim N(0, \sigma^2)$, e $\epsilon_i \perp \epsilon_j, \forall i \neq j$.

O modelo linear múltiplo

- Vamos assumir que temos duas ou mais variáveis explicativas.
- Seja Y um desfecho contínuo avaliado em n observações independentes, e de forma geral p variáveis explicativas X , ou seja,

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n,$$
$$\mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i}.$$

- Isso é o mesmo que escrever

$$Y_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i} + \epsilon_i$$

onde $\epsilon_i \sim N(0, \sigma^2)$, e $\epsilon_i \perp \epsilon_j, \forall i \neq j$.

O modelo linear múltiplo

- Forma matricial

$$Y = X\beta + e \quad e \sim N_n(0, \sigma^2 I_n)$$

onde Y é um vetor ($n \times 1$), X é uma matriz ($n \times (p + 1)$),
 $\beta = (\alpha, \beta_1, \dots, \beta_p)^T$, $\sigma^2 > 0$ e I_n é matriz identidade de ordem n .

- Estimador de mínimos quadrados (e EMV) para β

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

- $\hat{\beta}$ segue uma normal $(p + 1)$ -variada

$$\mathbb{E}[\hat{\beta}] = \beta \quad \mathbb{V}[\hat{\beta}] = \sigma^2 (X^T X)^{-1}$$

O modelo linear múltiplo

- Forma matricial

$$Y = X\beta + e \quad e \sim N_n(0, \sigma^2 I_n)$$

onde Y é um vetor $(n \times 1)$, X é uma matriz $(n \times (p + 1))$, $\beta = (\alpha, \beta_1, \dots, \beta_p)^T$, $\sigma^2 > 0$ e I_n é matriz identidade de ordem n .

- Estimador de minimos quadrados (e EMV) para β

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

- $\hat{\beta}$ segue uma normal $(p + 1)$ -variada

$$\mathbb{E}[\hat{\beta}] = \beta \quad \mathbb{V}[\hat{\beta}] = \sigma^2 (X^T X)^{-1}$$

O modelo linear múltiplo

- Forma matricial

$$Y = X\beta + e \quad e \sim N_n(0, \sigma^2 I_n)$$

onde Y é um vetor ($n \times 1$), X é uma matriz ($n \times (p + 1)$), $\beta = (\alpha, \beta_1, \dots, \beta_p)^T$, $\sigma^2 > 0$ e I_n é matriz identidade de ordem n .

- Estimador de minimos quadrados (e EMV) para β

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

- $\hat{\beta}$ segue uma normal $(p + 1)$ -variada

$$\mathbb{E}[\hat{\beta}] = \beta \quad \mathbb{V}[\hat{\beta}] = \sigma^2 (X^T X)^{-1}$$


Exemplo: Eficiência de ração do ganho de peso de ratos

- Considere um estudo realizado para avaliar a eficiência de ração no ganho de peso de ratos.
- Seja Y peso (em g) de 45 ratos com 20 dias de idade alimentados a partir do desmame por duas semanas com uma das três marcas diferentes de ração: Controle, autoclavada e irradiada.
- Os ratos também pertencem a 3 linhagens distintas: Swiss (baseline), Alox 5 e 129 PAS.


```
> summary(racao)
```

ID	Linhagem	Racao	Peso
Min. : 1	Swiss :27	Controle:15	Min. : 8.64
1st Qu.:12	129 PAS: 9	NovaAuto:15	1st Qu.:16.44
Median :23	ALOX 5 : 9	NovaIr :15	Median :27.20
Mean :23			Mean :23.98
3rd Qu.:34			3rd Qu.:30.30
Max. :45			Max. :37.80
			NA's :1


Visualizando os dados



Visualizando os dados



Visualizando os dados



- O modelo que incorpora a exposição e controla pela linhagem é dado por

$$Y_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 45,$$

$$\mu_i = \alpha + \beta_2 X_{1,i}^{(NovaAu)} + \beta_3 X_{1,i}^{(NovaIr)} + \beta_3 X_{2,i}^{(ALOX5)} + \beta_2 X_{2,i}^{(PAS129)}$$

onde X_1 é um fator para ração, e X_2 é um fator para a linhagem.

- A notação (no R) seria: *Peso* ~ *Racao* + *Linhagem*

O modelo linear no R

```
> modelo <- lm(Peso ~ Racao + Linhagem, data = racao)
> summary(modelo)
```

Call:

```
lm(formula = Peso ~ Racao + Linhagem, data = racao)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-4.0292	-1.3412	0.1531	1.4275	3.7783

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	34.0217	0.5450	62.422	< 2e-16 ***
RacaoNovaAuto	-6.7749	0.7087	-9.560	9.02e-12 ***
RacaoNovaIr	-4.8073	0.6962	-6.905	2.89e-08 ***
Linhagem129 PAS	-14.5277	0.7375	-19.698	< 2e-16 ***
LinhagemALOX 5	-16.0377	0.7375	-21.745	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.907 on 39 degrees of freedom

(1 observation deleted due to missingness)

Multiple R-squared: 0.9532, Adjusted R-squared: 0.9484

F-statistic: 198.5 on 4 and 39 DF, p-value: < 2.2e-16

A partir da saída

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	34.0217	0.5450	62.42	0.0000
RacaoNovaAuto	-6.7749	0.7087	-9.56	0.0000
RacaoNovalr	-4.8073	0.6962	-6.91	0.0000
Linhagem129 PAS	-14.5277	0.7375	-19.70	0.0000
LinhagemALOX 5	-16.0377	0.7375	-21.75	0.0000


Em média

- os ratos da linhagem Swiss tratados com a ração controle pesam 34g.
- as duas rações, Nova Irradiada e Nova autoclavada, reduzem o peso médio em 4.8 e 6.8g respectivamente quando comparadas ao controle.
- linhagem Swiss em média pesa 14.5g a mais que a 129 PAS, e 16g a mais que a linhagem ALOX 5.

Intervalos de confiança

```
> modelo.coef <- cbind(Est = coef(modelo), confint(modelo))
```

	Est	2.5 %	97.5 %
(Intercept)	34.02	32.92	35.12
RacaoNovaAuto	-6.77	-8.21	-5.34
RacaoNovalr	-4.81	-6.22	-3.40
Linhagem129 PAS	-14.53	-16.02	-13.04
LinhagemALOX 5	-16.04	-17.53	-14.55



- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

Análise de resíduos

- Os erros do modelo são definidos por

$$e_i = Y_i - \alpha - \sum_p X_{i,p} \beta_p$$

- O erro estimado, chamado de resíduo, é dado por

$$\hat{e}_i = Y_i - \hat{Y}_i = Y_i - \hat{\alpha} - \sum_p X_{i,p} \hat{\beta}_p$$

- Dos resíduos, no entanto, é

$$\hat{e}_i \sim N(0, \sigma^2(1 - h_{ii}))$$

onde h_{ii} é o i -ésimo elemento da diagonal da matriz H (matriz chapéu)

- Resíduos padronizados

$$r_i = \frac{\hat{e}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}$$

Análise de resíduos

- Os erros do modelo são definidos por

$$e_i = Y_i - \alpha - \sum_p X_{i,p} \beta_p$$

- O erro estimado, chamado de resíduo, é dado por

$$\hat{e}_i = Y_i - \hat{Y}_i = Y_i - \hat{\alpha} - \sum_p X_{i,p} \hat{\beta}_p$$

- Dos resíduos, no entanto, é

$$\hat{e}_i \sim N(0, \sigma^2(1 - h_{ii}))$$

onde h_{ii} é o i -ésimo elemento da diagonal da matriz H (matriz chapéu)

- Resíduos padronizados

$$r_i = \frac{\hat{e}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}$$

- Os erros do modelo são definidos por

$$e_i = Y_i - \alpha - \sum_p X_{i,p} \beta_p$$

- O erro estimado, chamado de resíduo, é dado por

$$\hat{e}_i = Y_i - \hat{Y}_i = Y_i - \hat{\alpha} - \sum_p X_{i,p} \hat{\beta}_p$$

- Dos resíduos, no entanto, é

$$\hat{e}_i \sim N(0, \sigma^2(1 - h_{ii}))$$

onde h_{ii} é o i -ésimo elemento da diagonal da matriz H (matriz chapéu)

- Resíduos padronizados

$$r_i = \frac{\hat{e}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}$$

- Os erros do modelo são definidos por

$$e_i = Y_i - \alpha - \sum_p X_{i,p} \beta_p$$

- O erro estimado, chamado de resíduo, é dado por

$$\hat{e}_i = Y_i - \hat{Y}_i = Y_i - \hat{\alpha} - \sum_p X_{i,p} \hat{\beta}_p$$

- Dos resíduos, no entanto, é

$$\hat{e}_i \sim N(0, \sigma^2(1 - h_{ii}))$$

onde h_{ii} é o i -ésimo elemento da diagonal da matriz H (matriz chapéu)


- Resíduos padronizados

$$r_i = \frac{\hat{e}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}$$

Suposição de normalidade


```
> hist(rstandard(modelo), col = 2)
```

Histogram of rstandard(modelo)



Suposição de normalidade

```
> qqnorm(rstandard(modelo) )  
> qqline(rstandard(modelo) )
```



Suposição de normalidade

Podemos testar a hipótese de normalidade usando o teste de Shapiro-Wilks ou teste de Kolmogorov-Smirnov

$$\begin{cases} H_0 : & \text{as observações seguem uma distribuição normal}(\mu, \sigma^2) \\ H_1 : & \text{as observações seguem outra distribuição.} \end{cases}$$

```
> shapiro.test(rstandard(modelo))
```

Shapiro-Wilk normality test

```
data: rstandard(modelo)
```

```
W = 0.97789, p-value = 0.5514
```

```
> ks.test(rstandard(modelo), y="pnorm")
```

Asymptotic one-sample Kolmogorov-Smirnov test

```
data: rstandard(modelo)
```


```
D = 0.096886, p-value = 0.8033
```

```
alternative hypothesis: two-sided
```

Variância constante (e padrões não-lineares)

Faz-se um scatter plot dos resíduos versus a ordem dos dados, e espera-se que a variância não tenha um padrão bem definido

```
> plot(rstandard(modelo))
```



Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (a distribuição dos erros é normal e a amostra for grande)
 - Variância constante (homoscedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influencia de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Homocedasticidade (resíduos com variância constante)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influência de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Variância constante (Homocedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influência de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Variância constante (Homocedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influência de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Variância constante (Homocedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influência de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Variância constante (Homocedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influência de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Variância constante (Homocedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influência de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Suponha agora que gostaríamos de ajustar diferentes modelos:

```
> modeloR <- lm(Peso ~ Racao, data = racao)
> modeloL <- lm(Peso ~ Linhagem, data = racao)
> modeloRL <- lm(Peso ~ Racao + Linhagem, data = racao)
> modeloRL2 <- lm(Peso ~ Racao * Linhagem, data = racao)
```

- Como podemos comparar diferentes modelos?
- Se os modelos forem aninhados* podemos usar a ANOVA no modelo mais completo
- Outra forma de comparar modelos é usando coeficiente de determinação e critérios de informação.

- Como podemos comparar diferentes modelos?
- Se os modelos forem aninhados* podemos usar a ANOVA no modelo mais completo
- Outra forma de comparar modelos é usando coeficiente de determinação e critérios de informação.

- Como podemos comparar diferentes modelos?
- Se os modelos forem aninhados* podemos usar a ANOVA no modelo mais completo
- Outra forma de comparar modelos é usando coeficiente de determinação e critérios de informação.

Testando a interação

No modelo mais completo temos o termo de interação *Racao : Linhagem*, podemos testar se algum dos termos da interação é significativo

```
> summary(modeloRL2)
```

Call:

```
lm(formula = Peso ~ Racao * Linhagem, data = racao)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.5889	-1.2083	0.1174	1.4931	4.0111

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	33.7889	0.6178	54.695	< 2e-16 ***
RacaoNovaAuto	-5.9014	0.9005	-6.553	1.45e-07 ***
RacaoNovaIr	-4.9111	0.8736	-5.621	2.44e-06 ***
Linhagem129 PAS	-13.8022	1.2355	-11.171	4.33e-13 ***
LinhagemALOX 5	-15.5989	1.2355	-12.625	1.37e-14 ***
RacaoNovaAuto:Linhagem129 PAS	-3.2019	1.7609	-1.818	0.0776 .
RacaoNovaIr:Linhagem129 PAS	0.9544	1.7473	0.546	0.5884
RacaoNovaAuto:LinhagemALOX 5	-0.9519	1.7609	-0.541	0.5922
RacaoNovaIr:LinhagemALOX 5	-0.4356	1.7473	-0.249	0.8046

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.853 on 35 degrees of freedom



Testando a interação

Testando usando a ANOVA de modelos, partindo do modelo nulo até o modelo completo

```
> #anova(modeloRL2)
> anova(lm(Peso ~ Racao*Linhagem, data = racao))
```

Analysis of Variance Table

Response: Peso

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Racao	2	393.98	196.99	57.3526	9.006e-12 ***
Linhagem	2	2492.67	1246.33	362.8666	< 2.2e-16 ***
Racao:Linhagem	4	21.55	5.39	1.5688	0.2043
Residuals	35	120.21	3.43		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Cada linha testa a igualdade do modelo anterior (o primeiro é o modelo nulo, i.e. $Y \sim 1$) e o modelo com a adição da variável daquela linha.

Testando a interação

Note que a ordem de entrada das covariáveis do modelo é importante

```
> anova(lm(Peso ~ Linhagem*Racao, data = racao))
```

Analysis of Variance Table

Response: Peso

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Linhagem	2	2531.06	1265.53	368.4555	< 2.2e-16 ***
Racao	2	355.58	177.79	51.7637	3.502e-11 ***
Linhagem:Racao	4	21.55	5.39	1.5688	0.2043
Residuals	35	120.21	3.43		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Dica: Se for usar esse recurso, inclua a sua exposição de interesse primeiro.

Podemos comparar dois modelos

```
> anova(modeloR, modeloRL2)
```

```
Analysis of Variance Table
```

```
Model 1: Peso ~ Racao
```

```
Model 2: Peso ~ Racao * Linhagem
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	41	2634.43				
2	35	120.21	6	2514.2	122	< 2.2e-16 ***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- O método da ANOVA para comparar modelos funciona bem para comparar modelos lineares alinhados
- Uma abordagem mais geral, pode usar coeficientes de determinação (R^2) e **critérios de informação**
- Os critérios de informação são construídos a partir da função de desvio (*deviance*)
- Essa função é dada por $-2 \log_e \hat{L}$, $\hat{L}$ é a verossimilhança ajustada
- Para o modelo linear a função desvio é dada por:

$$-2 \log_e \hat{L} = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} \sum_i (y_i - \hat{y}_i)^2$$

- O método da ANOVA para comparar modelos funciona bem para comparar modelos lineares alinhados
- Uma abordagem mais geral, pode usar coeficientes de determinação (R^2) e **critérios de informação**
- Os critérios de informação são construídos a partir da função de desvio (*deviance*)
- Essa função é dada por $-2 \log_e \hat{L}$, $\hat{L}$ é a verossimilhança ajustada
- Para o modelo linear a função desvio é dada por:

$$-2 \log_e \hat{L} = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} \sum_i (y_i - \hat{y}_i)^2$$

- O método da ANOVA para comparar modelos funciona bem para comparar modelos lineares alinhados
- Uma abordagem mais geral, pode usar coeficientes de determinação (R^2) e **critérios de informação**
- Os critérios de informação são construídos a partir da função de desvio (*deviance*)
- Essa função é dada por $-2 \log_e \hat{L}$, $\hat{L}$ é a verossimilhança ajustada
- Para o modelo linear a função desvio é dada por:

$$-2 \log_e \hat{L} = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} \sum_i (y_i - \hat{y}_i)^2$$

- O método da ANOVA para comparar modelos funciona bem para comparar modelos lineares alinhados
- Uma abordagem mais geral, pode usar coeficientes de determinação (R^2) e **critérios de informação**
- Os critérios de informação são construídos a partir da função de desvio (*deviance*)
- Essa função é dada por $-2 \log_e \hat{L}$, $\hat{L}$ é a verossimilhança ajustada
- Para o modelo linear a função desvio é dada por:

$$-2 \log_e \hat{L} = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} \sum_i (y_i - \hat{y}_i)^2$$

- O método da ANOVA para comparar modelos funciona bem para comparar modelos lineares alinhados
- Uma abordagem mais geral, pode usar coeficientes de determinação (R^2) e **critérios de informação**
- Os critérios de informação são construídos a partir da função de desvio (*deviance*)
- Essa função é dada por $-2 \log_e \hat{L}$, $\hat{L}$ é a verossimilhança ajustada
- Para o modelo linear a função desvio é dada por:

$$-2 \log_e \hat{L} = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} \sum_i (y_i - \hat{y}_i)^2$$

Coeficiente de determinação ajustado

- Vimos que o coeficiente de determinação mostra a proporção da variabilidade do desfecho que é explicada pela variabilidade das variáveis explicativas do modelo.
- O R^2 é dado por

$$R^2 = 1 - \frac{\sum_i (y - \hat{y}_i)^2}{\sum_i (y - \bar{y})^2}$$

- Quanto maior o número de variáveis explicativas maior o R^2 , logo um ajuste é necessário, ou seja,

$$R^2_{(adj)} = 1 - \frac{\sum_i (y - \hat{y}_i)^2 / (n - p - 1)}{\sum_i (y - \bar{y})^2 / (n - 1)}$$

Critério de informação

- Se compararmos a função desvio de dois modelos com o mesmo tamanho de amostra, temos que aquele com o menor valor é o melhor ajustado.
- No entanto, modelos com muitos parâmetros acabam sendo beneficiados. (*overfitting*)
- O critério de informação mais famoso foi proposto por Akaike (1974)

$$AIC = 2p - 2 \log_e \hat{L}$$

onde p é o número de parâmetros

- Outro critério também popular é o BIC, proposto por Schwarz (1978)

$$BIC = p \log_e n - 2 \log_e \hat{L}$$

- Ambos critérios penalizam modelos com mais parâmetros

Critério de informação

- Se compararmos a função desvio de dois modelos com o mesmo tamanho de amostra, temos que aquele com o menor valor é o melhor ajustado.
- No entanto, modelos com muitos parâmetros acabam sendo beneficiados. (*overfitting*)
- O critério de informação mais famoso foi proposto por Akaike (1974)

$$AIC = 2p - 2 \log_e \hat{L}$$

onde p é o número de parâmetros

- Outro critério também popular é o BIC, proposto por Schwarz (1978)

$$BIC = p \log_e n - 2 \log_e \hat{L}$$

- Ambos critérios penalizam modelos com mais parâmetros

Critério de informação

- Se compararmos a função desvio de dois modelos com o mesmo tamanho de amostra, temos que aquele com o menor valor é o melhor ajustado.
- No entanto, modelos com muitos parâmetros acabam sendo beneficiados. (*overfitting*)
- O critério de informação mais famoso foi proposto por Akaike (1974)

$$AIC = 2p - 2 \log_e \hat{L}$$

onde p é o número de parâmetros

- Outro critério também popular é o BIC, proposto por Schwarz (1978)

$$BIC = p \log_e n - 2 \log_e \hat{L}$$

- Ambos critérios penalizam modelos com mais parâmetros

Critério de informação

- Se compararmos a função desvio de dois modelos com o mesmo tamanho de amostra, temos que aquele com o menor valor é o melhor ajustado.
- No entanto, modelos com muitos parâmetros acabam sendo beneficiados. (*overfitting*)
- O critério de informação mais famoso foi proposto por Akaike (1974)

$$AIC = 2p - 2 \log_e \hat{L}$$

onde p é o número de parâmetros

- Outro critério também popular é o BIC, proposto por Schwarz (1978)

$$BIC = p \log_e n - 2 \log_e \hat{L}$$

- Ambos critérios penalizam modelos com mais parâmetros

Critério de informação

- Se compararmos a função desvio de dois modelos com o mesmo tamanho de amostra, temos que aquele com o menor valor é o melhor ajustado.
- No entanto, modelos com muitos parâmetros acabam sendo beneficiados. (*overfitting*)
- O critério de informação mais famoso foi proposto por Akaike (1974)

$$AIC = 2p - 2 \log_e \hat{L}$$

onde p é o número de parâmetros

- Outro critério também popular é o BIC, proposto por Schwarz (1978)

$$BIC = p \log_e n - 2 \log_e \hat{L}$$

- Ambos critérios penalizam modelos com mais parâmetros

- Os critérios de informação apresentados estão implementados no R
- As funções associadas se aplicam ao objeto do modelo ajustado
- No exemplo:

```
> AIC(modelo)
```

```
[1] 188.3463
```

```
> BIC(modelo)
```

```
[1] 199.0515
```

Critérios de informação no R

	df	AIC	BIC	R2	R2.adj
modeloR	4.00	312.92	320.06	13.01	8.77
modeloL	4.00	239.57	246.71	83.58	82.78
modeloRL	6.00	188.35	199.05	95.32	94.84
modeloRL2	10.00	189.09	206.93	96.03	95.12

Scottish Heart Health Study (SHHS)

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1. O IMC depende apenas do sexo.
 - 2. O IMC depende apenas do tabagismo.
 - 3. O IMC depende do sexo e do tabagismo.
 - 4. O IMC depende do sexo, do tabagismo, e da interação entre eles.

Scottish Heart Health Study (SHHS)

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - IMC (Y) versus tabagismo ($X_2 = \{N, L, H\}$)
 - IMC (Y) versus sexo e tabagismo (X_1, X_2)
 - IMC (Y) versus sexo e tabagismo e idade (X_1, X_2, X_3)

Scottish Heart Health Study (SHHS)

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1 IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - 2 IMC versus tabagismo ($X_2 = \{\text{current, ex, never}\}$)
 - 3 IMC versus sexo e tabagismo
 - 4 IMC versus sexo, tabagismo, e sua interação

Scottish Heart Health Study (SHHS)

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1 IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - 2 IMC versus tabagismo ($X_2 = \{\text{current, ex, never}\}$)
 - 3 IMC versus sexo e tabagismo
 - 4 IMC versus sexo, tabagismo, e sua interação

Scottish Heart Health Study (SHHS)

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1 IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - 2 IMC versus tabagismo ($X_2 = \{\text{current, ex, never}\}$)
 - 3 IMC versus sexo e tabagismo
 - 4 IMC versus sexo, tabagismo, e sua interação


Scottish Heart Health Study (SHHS)

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1 IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - 2 IMC versus tabagismo ($X_2 = \{\text{current, ex, never}\}$)
 - 3 IMC versus sexo e tabagismo
 - 4 IMC versus sexo, tabagismo, e sua interação


Scottish Heart Health Study (SHHS)

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1 IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - 2 IMC versus tabagismo ($X_2 = \{\text{current, ex, never}\}$)
 - 3 IMC versus sexo e tabagismo
 - 4 IMC versus sexo, tabagismo, e sua interação


Scottish Heart Health Study



Scottish Heart Health Study



Scottish Heart Health Study



Modelo 1: $BMI \sim Sex$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i}^{(2)}.$$

onde $X_1^{(1)}$ é a categorias de referência de sexo (Sex = M (male)).

```
> (modelo1.shhs <- lm(BMI ~ Sex, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex, data = SHHS)
```

Coefficients:

(Intercept)	SexM
25.220	1.112

Modelo 2: $BMI \sim Smoking$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)}.$$

onde $X_2^{(1)}$ é a categoria de referência de tabagismo (Smoking = current).

```
> (modelo2.shhs <- lm(BMI ~ Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Smoking, data = SHHS)
```

Coefficients:

(Intercept)	Smokingex	Smokingnever
24.527	1.691	2.279

Modelo 3: $BMI \sim Sex + Smoking$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_1 X_{1,i}^{(2)} + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)}.$$

```
> (modelo3.shhs <- lm(BMI ~ Sex + Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex + Smoking, data = SHHS)
```

Coefficients:

(Intercept)	SexM	Smokingex	Smokingnever
23.772	1.340	1.655	2.483

Modelo 4: $BMI \sim Sex + Smoking + Sex : Smoking$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_1 X_{1,i}^{(2)} + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)} + \beta_4 X_{1,i}^{(2)} X_{2,i}^{(2)} + \beta_5 X_{1,i}^{(2)} X_{2,i}^{(3)}.$$

```
> (modelo4.shhs <- lm(BMI ~ Sex * Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex * Smoking, data = SHHS)
```

Coefficients:

(Intercept)	SexM	Smokingex	Smokingnever
23.2333	2.2954	2.1017	3.5070
SexM:Smokingex	SexM:Smokingnever		
-0.8008	-2.1348		

Escolhendo modelo via ANOVA

```
> anova(modelo4.shhs)
```

Analysis of Variance Table

Response: BMI

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
Sex	1	46.28	46.279	4.2317	0.0414790	*
Smoking	2	167.76	83.880	7.6700	0.0006835	***
Sex:Smoking	2	29.78	14.892	1.3617	0.2595062	
Residuals	144	1574.81	10.936			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Escolhendo o modelo

	df	AIC	BIC	R2	R2.adj
BMI ~ Sex	3.00	802.10	811.13	2.54	1.89
BMI ~ Smoke	4.00	795.19	807.23	8.16	6.91
BMI ~ Sex + Smoke	5.00	791.18	806.23	11.77	9.96
BMI ~ Sex * Smoke	7.00	792.37	813.44	13.41	10.40

Saída do modelo final

```
> summary(modelo3.shhs)
```

Call:

```
lm(formula = BMI ~ Sex + Smoking, data = SHHS)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-9.5618	-2.1509	-0.2218	1.9846	9.4236

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	23.7718	0.5435	43.735	< 2e-16 ***
SexM	1.3400	0.5486	2.443	0.015779 *
Smokingex	1.6545	0.6707	2.467	0.014785 *
Smokingnever	2.4829	0.6498	3.821	0.000196 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.315 on 146 degrees of freedom


Multiple R-squared: 0.1177, Adjusted R-squared: 0.09956

F-statistic: 6.492 on 3 and 146 DF, p-value: 0.0003737

Análise de resíduos: Normalidade


```
> hist(rstandard(modelo3.shhs))
```

Histogram of rstandard(modelo3.shhs)



Análise de resíduos: Independência e homocedasticidade


```
> plot(rstandard(modelo3.shhs))
```



Modelo final: organizado

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	23.7718	0.5435	43.73	0.0000
SexM	1.3400	0.5486	2.44	0.0158
Smokingex	1.6545	0.6707	2.47	0.0148
Smokingnever	2.4829	0.6498	3.82	0.0002

Modelo final: coefplot



Exemplo: DMFT

- DMFT versus consumo de açúcar (Kg/ano) e tipo de país (Industrializado)

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i}.$$

- $n = 90$ países
- X_1 é o consumo de açúcar (kg per capita / ano)
- X_2 é a classificação do país

$$X_2 = \begin{cases} 1 & \text{se país industrializado,} \\ 2 & \text{se país em desenvolvimento.} \end{cases}$$

Exemplo: DMFT

- DMFT versus consumo de açúcar (Kg/ano) e tipo de país (Industrializado)

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i}.$$

- $n = 90$ países
- X_1 é o consumo de açúcar (kg per capita / ano)
- X_2 é a classificação do país

$$X_2 = \begin{cases} 1 & \text{se país industrializado,} \\ 2 & \text{se país em desenvolvimento.} \end{cases}$$

Exemplo: DMFT

- DMFT versus consumo de açúcar (Kg/ano) e tipo de país (Industrializado)

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i}.$$

- $n = 90$ países
- X_1 é o consumo de açúcar (kg per capita / ano)
- X_2 é a classificação do país

$$X_2 = \begin{cases} 1 & \text{se país industrializado,} \\ 2 & \text{se país em desenvolvimento.} \end{cases}$$

Exemplo: DMFT


- DMFT versus consumo de açúcar (Kg/ano) e tipo de país (Industrializado)

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i}.$$

- $n = 90$ países
- X_1 é o consumo de açúcar (kg per capita / ano)
- X_2 é a classificação do país

$$X_2 = \begin{cases} 1 & \text{se país industrializado,} \\ 2 & \text{se país em desenvolvimento.} \end{cases}$$

Exemplo: DMFT versus consumo de açúcar



Quatro modelos distintos

- Modelo 1:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo}$$

- Modelo 2:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais}$$

- Modelo 3:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_3 \text{Consumo:Pais}$$


- Modelo 4:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais} + \beta_3 \text{Consumo:Pais}$$

Ajuste dos modelos no R

```
> # Modelo ignorando o tipo de país
> modeloC <- lm(DMFT ~ Consumo, data = dmft)
> #
> # Modelo variando intercepto
> modeloCP <- lm(DMFT ~ Consumo + Pais, data = dmft)
> #
> # Modelo variando slope
> modeloC.int <- lm(DMFT ~ Consumo + Consumo:Pais,
+                   data = dmft)
> #
> # Modelo variando intercepto e slope
> modeloCP.int <- lm(DMFT ~ Consumo + Pais + Consumo:Pais,
+                    data = dmft)
```

Modelo 1: DMFT ~ Consumo



Modelo 1: DMFT $\sim$ Consumo

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.2966	0.3062	4.23	0.0001
Consumo	0.0451	0.0089	5.06	0.0000


```
> AIC(modeloC)
```

```
[1] 319.3474
```

```
> BIC(modeloC)
```

```
[1] 326.8468
```

Modelo 2: DMFT ~ Consumo + País



Modelo 2: DMFT $\sim$ Consumo + Pais

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.6774	0.4998	3.36	0.0012
Consumo	0.0403	0.0102	3.94	0.0002
PaisEm desenvolvimento	-0.3479	0.3608	-0.96	0.3375


```
> AIC(modeloCP)
```

```
[1] 320.3903
```

```
> BIC(modeloCP)
```

```
[1] 330.3895
```

Modelo 3: $DMFT \sim \text{Consumo} + \text{Consumo}:\text{País}$



Modelo 3: $DMFT \sim \text{Consumo} + \text{Consumo:Pais}$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.3211	0.3129	4.22	0.0001
Consumo	0.0464	0.0094	4.92	0.0000
Consumo:PaisEm desenvolvimento	-0.0038	0.0087	-0.43	0.6680


```
> AIC(modeloC.int)
```

```
[1] 321.156
```

```
> BIC(modeloC.int)
```

```
[1] 331.1552
```

Modelo 4: DMFT ~ Consumo*País



Modelo 4: DMFT $\sim$ Consumo*Pais

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.9086	1.2865	3.04	0.0032
Consumo	-0.0131	0.0301	-0.43	0.6658
PaisEm desenvolvimento	-2.7439	1.3248	-2.07	0.0413
Consumo:PaisEm desenvolvimento	0.0600	0.0320	1.88	0.0638

```
> AIC(modeloCP.int)
```

```
[1] 318.7751
```

```
> BIC(modeloCP.int)
```


```
[1] 331.2742
```

Escolhendo o modelo


	Modelo	AIC	BIC	R2	R2.adj
1	Consumo	319.35	326.85	22.53	21.65
2	Consumo + Pais	320.39	330.39	23.35	21.59
3	Consumo + Consumo:Pais	321.16	331.16	22.70	20.92
4	Consumo*Pais	318.78	331.27	26.37	23.80

Análise de resíduos do Modelo 4


Histogram of rstandard(modeloCP.int)



Análise de resíduos do Modelo 4



Análise de resíduos



Funções “não lineares”

- Em algumas situações a relação linear entre desfecho Y e exposição X pode não ser razoável.
- Podemos escrever alguns modelos não-lineares e ainda assim usar métodos de estimação de modelos lineares.
- São exemplos:

Modelo exponencial

$$Y = \beta_0 \exp(\beta_1 X) \quad \text{ou} \quad \ln(Y) = \ln(\beta_0) + \beta_1 X$$

Modelo polinomial

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \dots$$

Modelo logarítmico

$$Y = \beta_0 + \beta_1 \ln(X)$$

Funções “não lineares”

- Em algumas situações a relação linear entre desfecho Y e exposição X pode não ser razoável.
- Podemos escrever alguns modelos não-lineares e ainda assim usar métodos de estimação de modelos lineares.
- São exemplos:

- Modelo de exponencial:

$$Y = A \exp\{BX\}e \quad \equiv \quad \log(Y) = \log(A) + BX + \log(e)$$

- Modelo polinomial (exemplo de 2º grau):

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + e$$

- Modelo logístico:

$$\log\left(\frac{Y}{1-Y}\right) = \beta_0 + \beta_1 X$$

Funções “não lineares”

- Em algumas situações a relação linear entre desfecho Y e exposição X pode não ser razoável.
- Podemos escrever alguns modelos não-lineares e ainda assim usar métodos de estimação de modelos lineares.
- São exemplos:
 - Modelo de exponencial:

$$Y = A \exp\{BX\}\epsilon \quad \equiv \quad \log(Y) = \log(A) + BX + \log(\epsilon)$$

- Modelo polinomial:

$$Y = \alpha + X\beta_1 + X^2\beta_2 + \cdots + X^p\beta_p$$

- Modelo logaritmo

$$Y = \alpha + \beta \log(X) + \epsilon$$

Funções “não lineares”

- Em algumas situações a relação linear entre desfecho Y e exposição X pode não ser razoável.
- Podemos escrever alguns modelos não-lineares e ainda assim usar métodos de estimação de modelos lineares.
- São exemplos:
 - Modelo de exponencial:

$$Y = A \exp\{BX\}\epsilon \quad \equiv \quad \log(Y) = \log(A) + BX + \log(\epsilon)$$

- Modelo polinomial:

$$Y = \alpha + X\beta_1 + X^2\beta_2 + \cdots + X^p\beta_p$$

- Modelo logaritmo

$$Y = \alpha + \beta \log(X) + \epsilon$$

Funções “não lineares”

- Em algumas situações a relação linear entre desfecho Y e exposição X pode não ser razoável.
- Podemos escrever alguns modelos não-lineares e ainda assim usar métodos de estimação de modelos lineares.
- São exemplos:
 - Modelo de exponencial:

$$Y = A \exp\{BX\}\epsilon \quad \equiv \quad \log(Y) = \log(A) + BX + \log(\epsilon)$$

- Modelo polinomial:

$$Y = \alpha + X\beta_1 + X^2\beta_2 + \cdots + X^p\beta_p$$

- Modelo logarítimo

$$Y = \alpha + \beta \log(X) + \epsilon$$

Funções “não lineares”

- Em algumas situações a relação linear entre desfecho Y e exposição X pode não ser razoável.
- Podemos escrever alguns modelos não-lineares e ainda assim usar métodos de estimação de modelos lineares.
- São exemplos:
 - Modelo de exponencial:

$$Y = A \exp\{BX\}\epsilon \quad \equiv \quad \log(Y) = \log(A) + BX + \log(\epsilon)$$

- Modelo polinomial:

$$Y = \alpha + X\beta_1 + X^2\beta_2 + \cdots + X^p\beta_p$$

- Modelo logaritmo

$$Y = \alpha + \beta \log(X) + \epsilon$$

Transformações

- Existem transformações no desfecho que visam “estabilizar” a variância. Box e Cox (1964) propuseram a seguinte

$$Y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{se } \lambda \neq 0, \\ \log(y_i), & \text{se } \lambda = 0 \end{cases}$$

conhecida por transformação de Box-Cox.

- Padronizar variáveis explicativas contínuas torna diferentes coeficientes adimensionais e comparáveis

$$\begin{aligned} Y_i &= \alpha + \beta X + e \\ &= \alpha + \frac{sd_x}{sd_x} \beta (X + \bar{X} - \bar{X}) + e \\ &= \alpha^* + \beta^* \frac{(X - \bar{X})}{sd_x} + e \end{aligned}$$

onde $\alpha^* = \alpha + \beta \bar{X}$ e $\beta^* = \beta sd_x$

Transformações

- Existem transformações no desfecho que visam “estabilizar” a variância. Box e Cox (1964) propuseram a seguinte

$$Y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{se } \lambda \neq 0, \\ \log(y_i), & \text{se } \lambda = 0 \end{cases}$$

conhecida por transformação de Box-Cox.

- Padronizar variáveis explicativas contínuas torna diferentes coeficientes adimensionais e comparáveis

$$\begin{aligned} Y_i &= \alpha + \beta X + e \\ &= \alpha + \frac{sd_x}{sd_x} \beta (X + \bar{X} - \bar{X}) + e \\ &= \alpha^* + \beta^* \frac{(X - \bar{X})}{sd_x} + e \end{aligned}$$

onde $\alpha^* = \alpha + \beta \bar{X}$ e $\beta^* = \beta sd_x$

Transformando o desfecho no exemplo da dieta

```
> output2 <- lm(log(DMFT) ~ Consumo*Pais, data = dmft)
> summary(output2)
```

Call:

```
lm(formula = log(DMFT) ~ Consumo * Pais, data = dmft)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.55029	-0.25373	-0.02022	0.34053	1.24113

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.38711	0.51021	2.719	0.00793 **
Consumo	-0.00588	0.01195	-0.492	0.62407
PaisEm desenvolvimento	-1.29160	0.52540	-2.458	0.01596 *
Consumo:PaisEm desenvolvimento	0.02727	0.01268	2.150	0.03432 *


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5457 on 86 degrees of freedom


Multiple R-squared: 0.3362, Adjusted R-squared: 0.3131

F-statistic: 14.52 on 3 and 86 DF, p-value: 9.834e-08


Transformando o desfecho no exemplo da dieta




Adicionando a incerteza




Histogram of rstandard(output2)



Normal Q-Q Plot



Análise de resíduos



- Slides e código (em R) para replicar as análises

<https://github.com/lsbastos/md32>